WYDZIAŁ ZASTOSOWAŃ INFORMATYKI I MATEMATYKI

UCZENIE MASZYNOWE

WYKŁAD 01

dr inż. Izabella Antoniuk
Instytut Informatyki Technicznej, Katedra Sztucznej Inteligencji, Zakład Analizy Obrazów
izabella_antoniuk@sggw.edu.pl

STRUKTURA PRZEDMIOTU

1. Wstęp teoretyczny
2. Kluczowe koncepcje
3. Podstawy projektowania rozwiązań ML
4. Przygotowanie i prezentacja projektu

PROJEKT

W ramach projektu należy wybrać i zaimplementować wybrane rozwiązanie z dziedziny ML.

Projekt musi dotyczyć praktycznego rozwiązania i w jego ramach powinna powstać działająca aplikacja.

Przy wyborze projektu należy zwrócić uwagę na dostępność danych.

PROJEKT

Częścią oceny projektu jest jego prezentacja – może się ona odbyć na ostatnich zajęciach, lub najpóźniej przed ostatnimi zajęciami z kursu (21.12.2025). Sugerowany termin: 20.12.2025, po zajęciach z Zaawansowanego Programowania w Pythonie.

W ramach prezentacji należy krótko omówić wykonany projekt, jego założenia, proces trenowania modelu oraz otrzymane wyniki (max 5-10 min).

Uczenie Maszynowe

Uczenie maszynowe (ang. Machine Learning) – gałąź sztucznej inteligencji, koncentrująca się na tworzeniu modeli i algorytmów, pozwalających komputerom uczyć się na podstawie danych bez konieczności programowania każdego zadania.

Można powiedzieć, że podejście to „uczy” systemy myśleć i rozumować jak ludzie, poprzez odnajdywanie zależności w danych.

Uczenie Maszynowe

Trzy główne podejścia:

Uczenie nadzorowane: trenuje modele na danych oznaczonych, w celu predykcji trendu lub klasyfikacji nowych danych (ang. Supervised Learning).

Uczenie nienadzorowane: wyszukuje wzorce lub grupy w danych nieoznaczonych, np. wyodrębnienie klastrów, redukcja wymiarów danych (ang. Unsupervised Learning).

Uczenie przez wzmacnianie: uczenie metodą prób i błędów, w celu maksymalizowania nagród otrzymywanych przez agenta (ang. Reinforcement Learning).

Uczenie Maszynowe

W ostatnich latach pojawiły się również nowe podejścia, które stopniowo zyskują na znaczeniu:

Uczenie samonadzorowane: podzbiór uczenia bez nadzoru, rozwinęło się w odrębną dziedzinę ze względu na sukces w trenowaniu modeli wielkoskalowych. Generuje ono własne etykiety z danych, bez konieczności ręcznego etykietowania (ang. Self-Supervised Learning).

Uczenie półnadzorowane: łączy niewielką ilość danych oznaczonych z dużą ilością danych nieoznaczonych. Przydatne, gdy etykietowanie danych jest kosztowne lub czasochłonne (ang. Semi-Supervised Learning).

Struktury danych

Dane mogą występować w najróżniejszych postaciach:

- Dane finansowe
- Pliki tekstowe
- Pliki multimedialne
- Mapowania genetyczne
- Szeregi czasowy
- Sygnały
- Etc.

Struktury danych

W zależności od źródła i stopnia przetworzenia/wyczyszczenia, będzie się różnić poziom ustrukturyzowania danych:

Dane nieustrukturyzowane – brak wewnętrznej struktury;

Dane quasi-strukturalne – pliki danych tekstowych bez formatowania, które można sformatować kosztem wysiłku i czasu; tj. dane z niespójnościami w wartościach i formatach danych;

Dane częściowo ustrukturyzowane – pliki z dostrzegalnym wzorcem, który umożliwia analizę.

Dane strukturalne – dane zawierające określony typ, format i strukturę danych.

Struktury danych

Większość dostępnych danych nie będzie ustrukturyzowana

Zwykle, zanim przejdziemy do tworzenia rozwiązań Uczenia Maszynowego, musimy zebrać i wstępnie przeanalizować oraz wyczyścić i ustrukturyzować dane.

Struktury danych

Proces analizy danych obejmuje kilka kluczowych kroków:

- Zrozumienie problemu
- Zbieranie danych
- Czyszczenie danych
- Eksploracja i analiza danych
- Interpretacja wyników

Struktury danych

!UWAGA

Na etapie zbierania danych należy również wziąć pod uwagę formę przechowywania i sposób zabezpieczania danych. Żyjemy w czasach, gdy pojęcie Big Data jest właściwie codziennością i przy większości zastosowań, możemy bezpiecznie założyć, że przetwarzane zbiory danych będą rozległe – a w związku z tym będą wymagały specjalnego przechowywania i przetwarzania.

BI vs Data Science

Analiza danych często wiąże się z co najmniej jednym z poniższych dwóch terminów:

Business Intelligence (BI) wykorzystujemy w sytuacjach, gdy potrzebujemy wglądu w dane z przeszłości, tj.: ile sztuk produktu sprzedano w ostatnim kwartale, które sklepy wypadły najlepiej i inne pytania zamknięte.

Data Science ma charakter bardziej predykcyjny i służy do analizowania danych w bardziej przyszłościowy, eksploracyjny sposób. Ma on zapewnić pewien wgląd w trendy, abyśmy mogli podejmować bardziej świadome decyzje dotyczące przyszłych działań.

Gdzie w tym wszystkim Big Data?

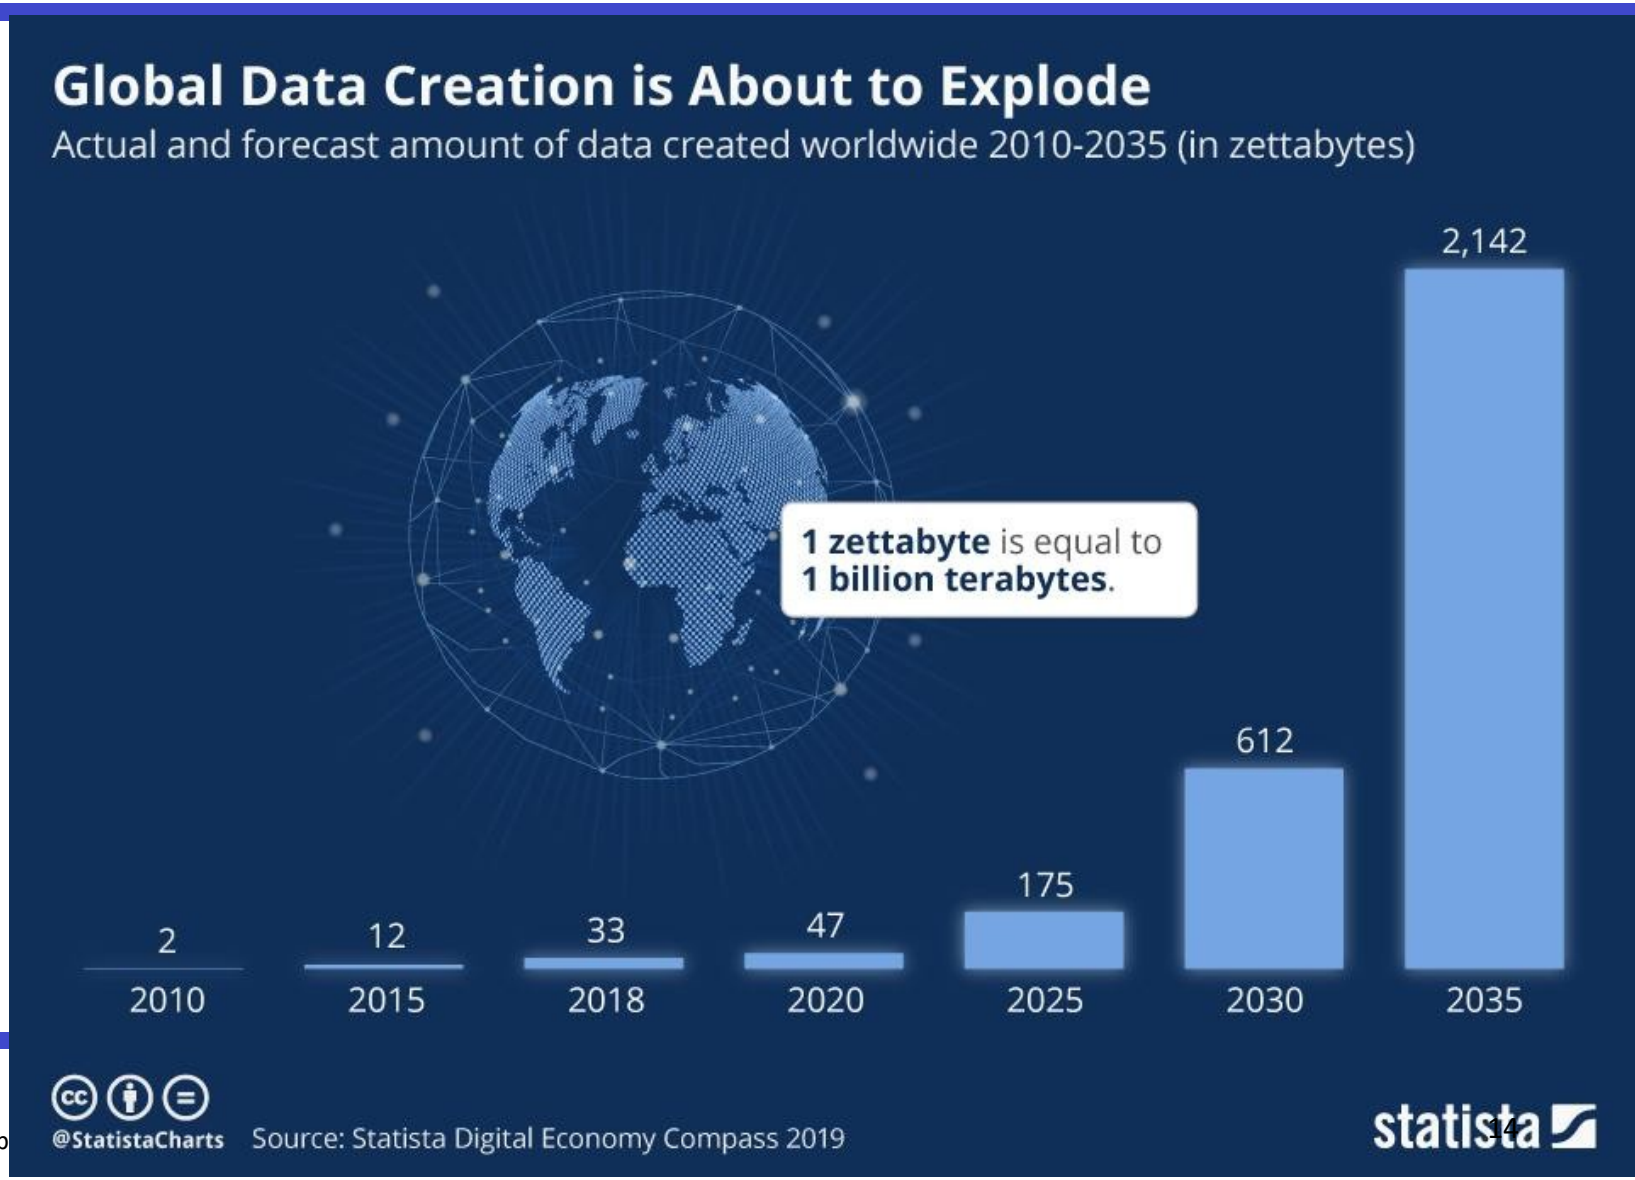

Big Data – główne parametry

Źródło: https://www.linkedin.com/pulse/big-data-management-revolutio-parichehr-esmailian

Analiza danych, proces

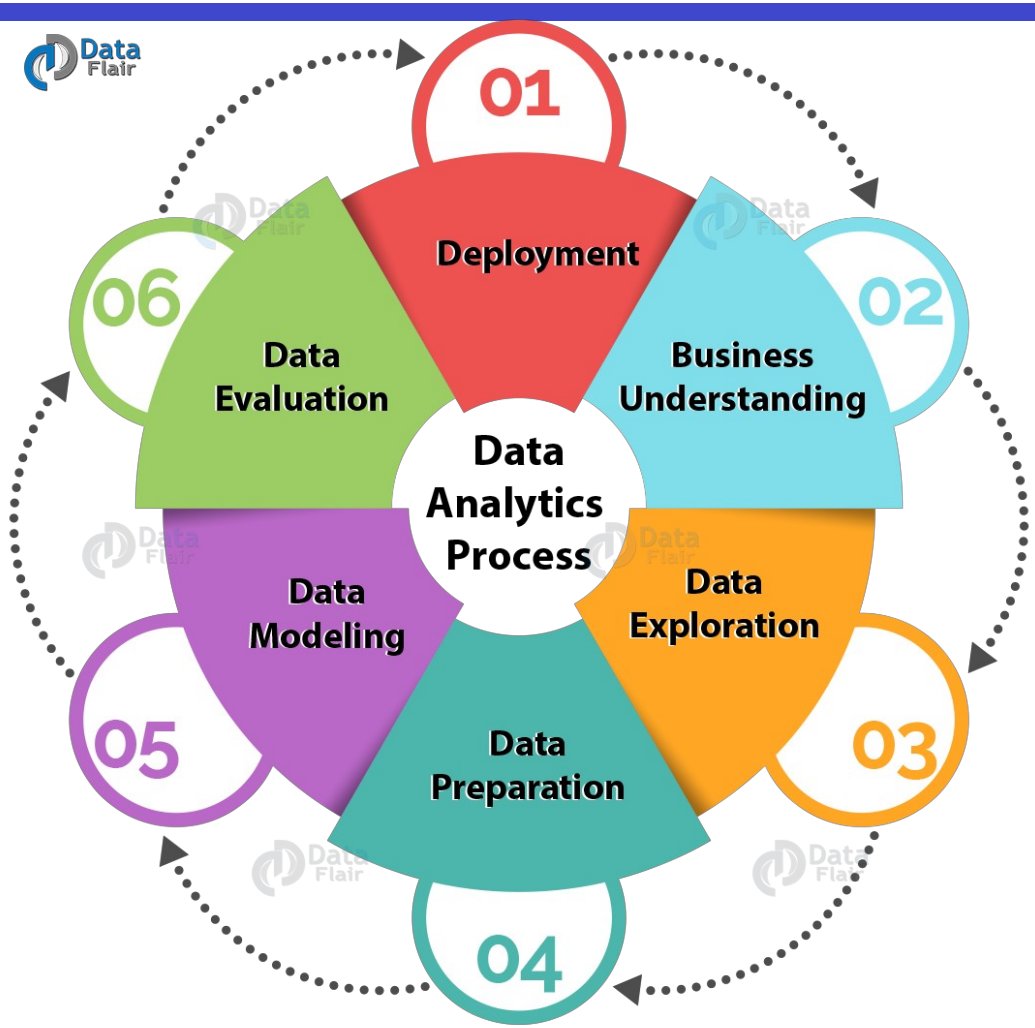

Źródło: https://medium.com/@patelharshali136/what-is-big-data-analytics-and-why-it-is-so-important-1de86fa37540

PROCES ANALIZY DANYCH

ML – nowy projekt

Pytanie – od czego zaczęlibyście nowy projekt?

ML – nowy projekt

Pytanie – od czego zaczęlibyście nowy projekt?

NIE należy spieszyć się ze zbieraniem i analizą danych.

Kluczowe kroki:

- Planowanie i określanie zakresu prac
- Zrozumienie wymagań
- Upewnienie się, że problem biznesowy jest odpowiednio sformułowany
- Tworzenie i dokumentowanie procesu

ML – dwa główne procesy

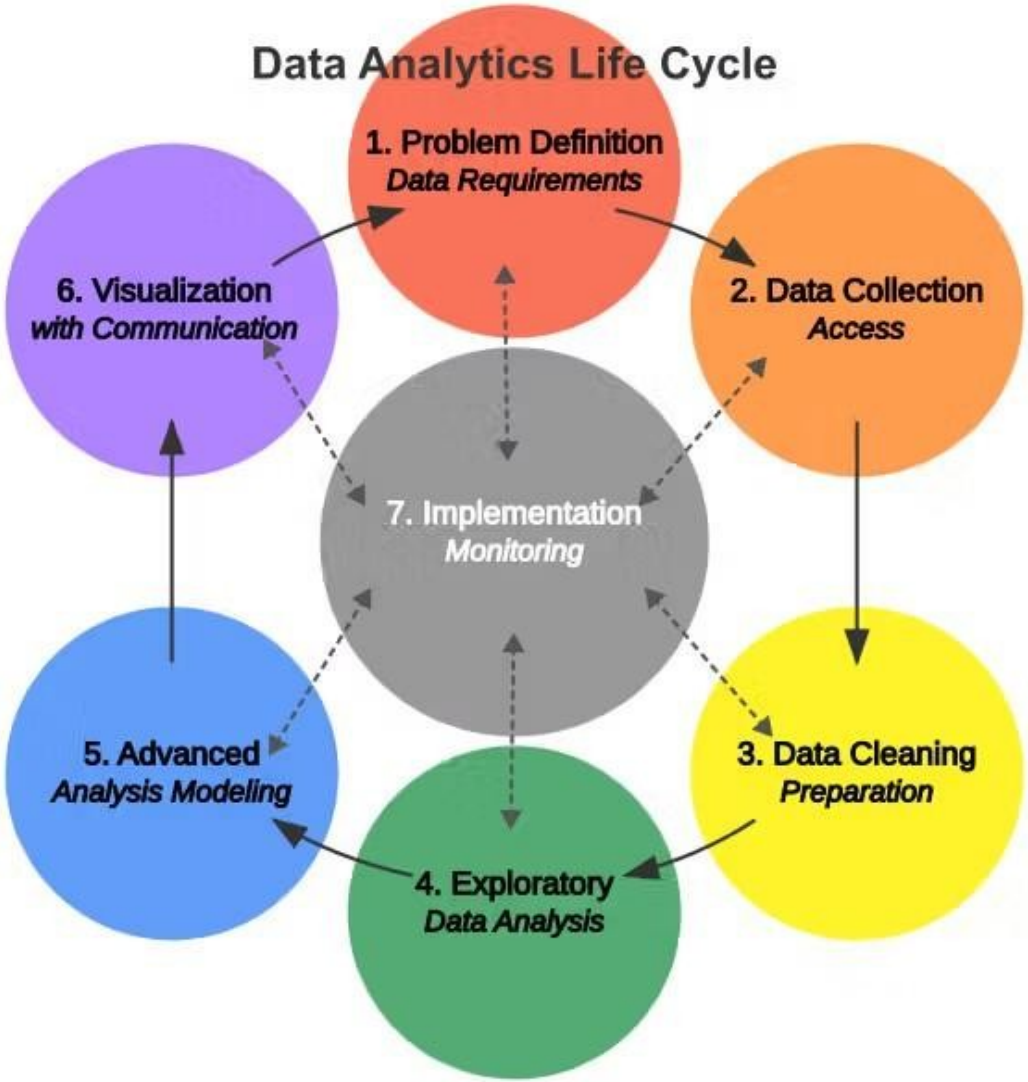

Legend: The hub-and-spoke model of data analytics where Implementation Monitoring connects with all phases of the analytical process

Źródło: https://www.quadratichq.com/blog/understanding-the-data-analytics-lifecycle-from-end-to-end

ML – dwa główne procesy

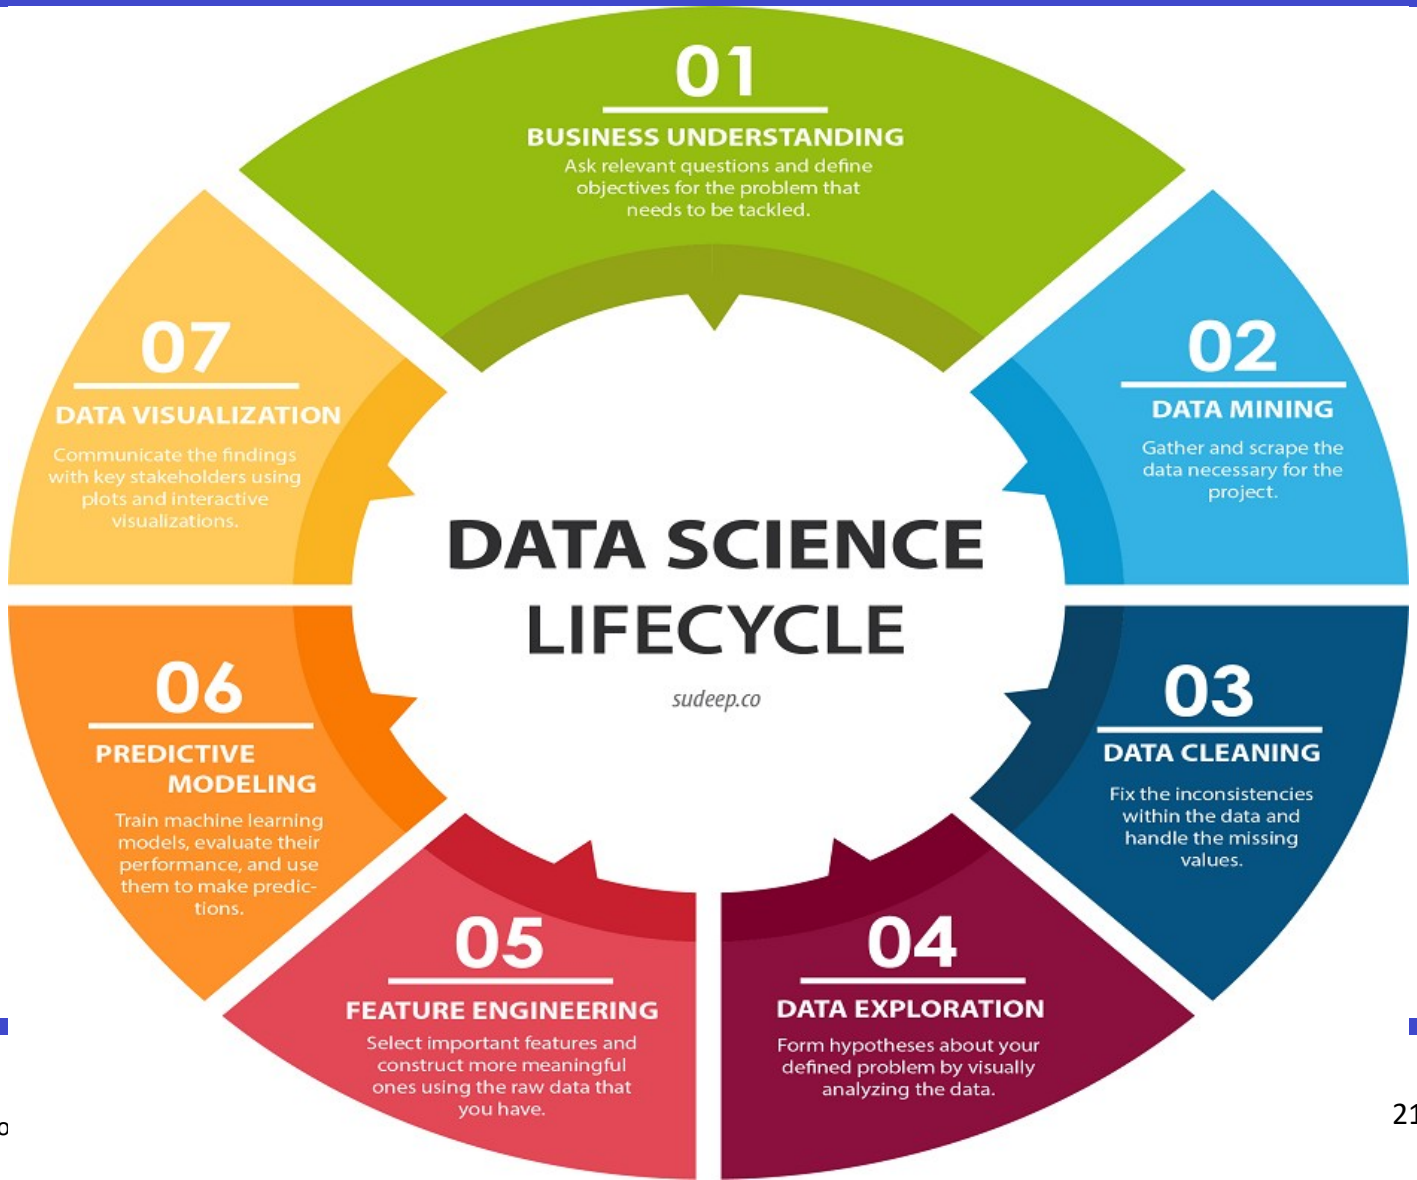

Źródło: https://analyticstrainninghub.com/life-cycle-of-data-science/

Analiza danych

Wyjdziemy z analizy danych, jako że jest to szerszy proces i obejmuje więcej różnorodnych przypadków.

Bardzo często będzie też wstępem do różnych projektów, tak z dziedziny Uczenia Maszynowego, jak i innych.

1. Definicja problemu

- Poznanie obszaru biznesowego;
- Sprawdzenie historii (Czy próbowano wcześniej zrobić to, co robimy obecnie, a jeśli tak i się nie udało to dlaczego? Jeżeli się udało, to dlaczego nie korzystamy z gotowego rozwiązania?);
- Ocena dostępnych zasobów;
- Ujęcie problemu biznesowego jako zadania analitycznego, którym będziemy się zajmować w kolejnych etapach;
- Formułowanie wstępnych hipotez;
- Identyfikacja potencjalnych źródeł danych, zlokalizowanie zagregowanych źródeł danych i przeglądanie surowych danych.

2. Zbieranie danych

- Jakie dane są dostępne od ręki?
- Czy zbieramy dane od zera, czy są dostępne istniejące zbiory danych?
- Czy mamy dane testowe?
- Czy wiemy jakie dane będą potrzebne?
- Czy znamy jakość i strukturę danych?
- Czy mamy dostęp do danych?
- Czy mamy opracowane metodologie zbierania, zabezpieczania, dokumentowania i przechowywania danych?
- Jakie problemy możemy napotkać? Jakie są główne zagrożenia związane z tym krokiem?

3. Czyszczenie danych

- Wprowadzanie danych do obszaru roboczego
- Przekształcanie dostępnych danych
- Wstępna analiza w celu określenia struktury danych i ewentualnych problemów, np.:
  - Dane brakujące
  - Wartości odstające
  - Różnice w rządzie wielkości
  - Korelacje
  - Inne zależności, mające wpływ na analizę i późniejsze trenowanie modelu, np. ogólna jakość danych, poprawność, potencjalne nieścisłości i błędy w danych.

4. Zaawansowana analiza + model

- Opracowywanie zbioru danych do celów testowych, trenowania modelu.
- Budowanie i testowanie modeli na podstawie wcześniejszych prac.
- Sprawdzenie, czy istnieją gotowe narzędzia spełniające założenia zadania, czy będzie potrzebne bardziej rozbudowane środowisko.

4. Zaawansowana analiza + model

Ponieważ w tym momencie powinniśmy wiedzieć więcej na temat naszych danych, możemy więc ponownie ocenić problem i wybrane podejście:

- Czy model wydaje się prawidłowy i dostatecznie dokładny po sprawdzeniu danych testowych?
- Czy wyniki/zachowanie modelu mają sens dla ekspertów dziedzinowych? Czy model daje odpowiedzi, które mają sens w tym kontekście?
- Czy wartości parametrów wytrenowanego modelu mają sens w kontekście dziedziny?
- Czy model jest wystarczająco dokładny?

4. Zaawansowana analiza + model

- Czy model unika niedopuszczalnych błędów?
- Czy potrzeba więcej danych lub więcej parametrów wejściowych? Czy któreś z wejść wymaga przekształcenia lub wyeliminowania?
- Czy wybrany model będzie spełniał wymagania dotyczące czasu działania?
- Czy do rozwiązania problemu biznesowego wymagana jest inna forma modelu?

5. Wizualizacja i przedstawienie wyników

- Prezentacja dotychczasowych rezultatów projektu.
- Na tym etapie należy określić, czy projekt/fragment projektu zakończył się sukcesem, czy porażką
- Należy zidentyfikować kluczowe ustalenia, określić ilościowo wartość biznesową i opracować narrację do prezentacji wyników końcowych.

!UWAGA

Przy prezentacji wyników należy brać pod uwagę dla kogo będziemy prezentować.

Dyskusja

Wstępna analiza projektu:

- Narzędzie poprawiające monetyzację i utrzymanie gracza w grze mobilnej.
- System usprawniający zarządzanie powierzchnią magazynową dla firmy transportowej.

PODSTAWOWE METODY

Podstawowe metody

Pierwsza faza analizy zwykle obejmuje różne aspekty eksploracji danych.

Zrozumienie danych jest jednym z kluczowych wymagań udanego projektu.

Wybór technik będzie w dużym stopniu zależny od rodzaju i wymagań projektu.

Próbkowanie

Technika statystyczna, w której analizowany jest mniejszy podzbiór danych zamiast całego zbioru danych.

Pozwala szybko uzyskać wgląd w strukturę danych i podjąć wstępne decyzje.

Główny problem: jak wybrać podzbiór próbki?

Próbkowanie

Jeśli dane są jednorodne i dobrze rozłożone, idealnym rozwiązaniem może być losowe pobieranie próbek.

Próbkowanie warstwowe jest dobrym rozwiązaniem w przypadku danych heterogenicznych z różnymi podgrupami.

Próbkowanie klastrowe można stosować w przypadku dużych i rozproszonych danych.

Jeśli dane są uporządkowane sekwencyjnie, możemy zastosować **próbkowanie systematyczne**.

Próbkowanie

Każda metoda próbkowania ma ograniczenia, takie jak wprowadzenie błędu lub błędu systematycznego (ang. bias), jeśli próbka nie reprezentuje dobrze populacji.

Aby temu zapobiec, metoda wybierania próbek, rozmiar i źródło danych muszą być odpowiednie do charakterystyki danych i rozwiązywanego problemu.

Próbkowanie

Błąd próbkowania – różnica między statystyką próbki a populacji, wynikająca z przypadkowych lub systematycznych zmian w próbach.

Aby je zminimalizować, należy zastosować odpowiednią metodę pobierania próbek, obliczyć margines błędu i przedział ufności oraz przeprowadzić kontrolę czułości i odporności (ang. Sensitivity, robustness).

Próbkowanie

Złożoność próbkowania – trudność lub koszt uzyskania i przetworzenia próbki.

Zwykle, aby rozwiązać ten problem, musimy użyć odpowiednich narzędzi, aby zmniejszyć problemy wynikające np. z różnych formatów danych, źródeł lub struktur obecnych w danych, a także ogólnej jakości danych.

Próbkowanie

Próbkowanie adaptacyjne – dostosowuje strategię lub rozmiar próbkowania na podstawie informacji zwrotnych z poprzednich próbek.

Resampling – generuje wiele próbek z oryginalnego zbioru danych w celu oszacowania rozkładu lub przeprowadzenia testów statystycznych.

Integracja próbkowania – łączy różne próbki lub metody próbkowania w celu uzyskania bardziej kompleksowej i reprezentatywnej próbki.

Próbkowanie

Stosowanie tych technik może:

- Zmniejsz błąd i bias próbkowania
- Zwiększ dokładność i wiarygodność (ang. validity)
- Zwiększ zasięg i różnorodność próbek
- Zmniejsz złożoność

Próbkowanie

Niezbędny jest wybór właściwej metody próbkowania.

Aby uniknąć błędów wynikających ze stosowania niewłaściwych metod doboru próby, ważne jest zrozumienie analizowanej dziedziny. Jeśli nie jesteśmy pewni, jak wyglądają dane, warto skonsultować się ze specjalistą.

Zrozumienie sposobu wykorzystania danych jest również kluczową informacją dla tego procesu.

Próbkowanie

Kluczowe kroki zapewniające dokładne próbkowanie i partycjonowanie danych.

1. Zdefiniuj cele i kryteria
2. Wybierz najlepiej dopasowaną metodę próbkowania
3. Stosuj spójne i powtarzalne partycjonowanie (szkolenie, walidacja, testowanie)
4. Użyj odpowiednich narzędzi i bibliotek (na przykład pandas i numpy do losowego próbkowania, scikit-learn do warstwowego próbkowania i partycjonowania, imbalanced-learn do niezrównoważonych danych itp.)
5. Oceń i porównaj wyniki
6. Eksperymentuj i iteruj

Model z próbek

Kiedy wykorzystujemy duże zbiory danych, prawie nigdy nie jesteśmy w stanie wykorzystać całego zbioru do budowy modelu.

W przypadku analizy opartej na próbkowanych danych, a nie na całym zestawie, dokładność (ang. Accuracy) nie powinna być używana jako jedyna miara modelu. Zamiast tego lepiej użyć precyzji, parametru recall i wyniku f1, aby określić jakość modelu.

Model z próbek

Innym sposobem na wyeliminowanie błędu systematycznego w modelu opracowanym na podstawie próbek jest regularyzacja. Możemy użyć regularyzacji Lasso (L1) lub Ridge (L2), aby zminimalizować wpływ cech o większym zakresie danych.

Brakujące dane

Brakujące dane mogą zmniejszyć wielkość próby, wprowadzić błąd, zniekształcić rozkład, a w rezultacie wpłynąć na dokładność i wiarygodność wyników.

Ważne jest, aby zidentyfikować wzorce i przyczyny brakujących danych w wybranym zbiorze danych i odpowiednio sobie z nimi poradzić.

Brakujące dane

Pierwszym krokiem jest określenie, ile i jakiego rodzaju brakujące dane są w zbiorze.

Możemy sprawdzić statystyki typów danych w kolumnach i wierszach.

Innym sposobem jest użycie funkcji takich jak isnull(), isna(), heatmap(), matrix(), info(), describe() itp., które pomogą policzyć liczbę brakujących wartości, a także uzyskać więcej szczegółów.

Brakujące dane

W przypadku zbiorów danych z dużą liczbą parametrów najlepszym rozwiązaniem może być ich zwizualizowanie z wykorzystaniem mapy cieplnej (ang. Heatmap). Jest to intuicyjny i graficzny sposób reprezentowania danych, pozwalający łatwo dostrzec wzorce, trendy i/lub obszary koncentracji brakujących danych.

Brakujące dane

W mapie cieplnej każda komórka reprezentuje punkt danych w zbiorze danych. Zwykle do oznaczania brakujących i pełnych danych używamy różnych kolorów. W ten sposób możemy szybko sprawdzić, czy występują jakieś wzorce.

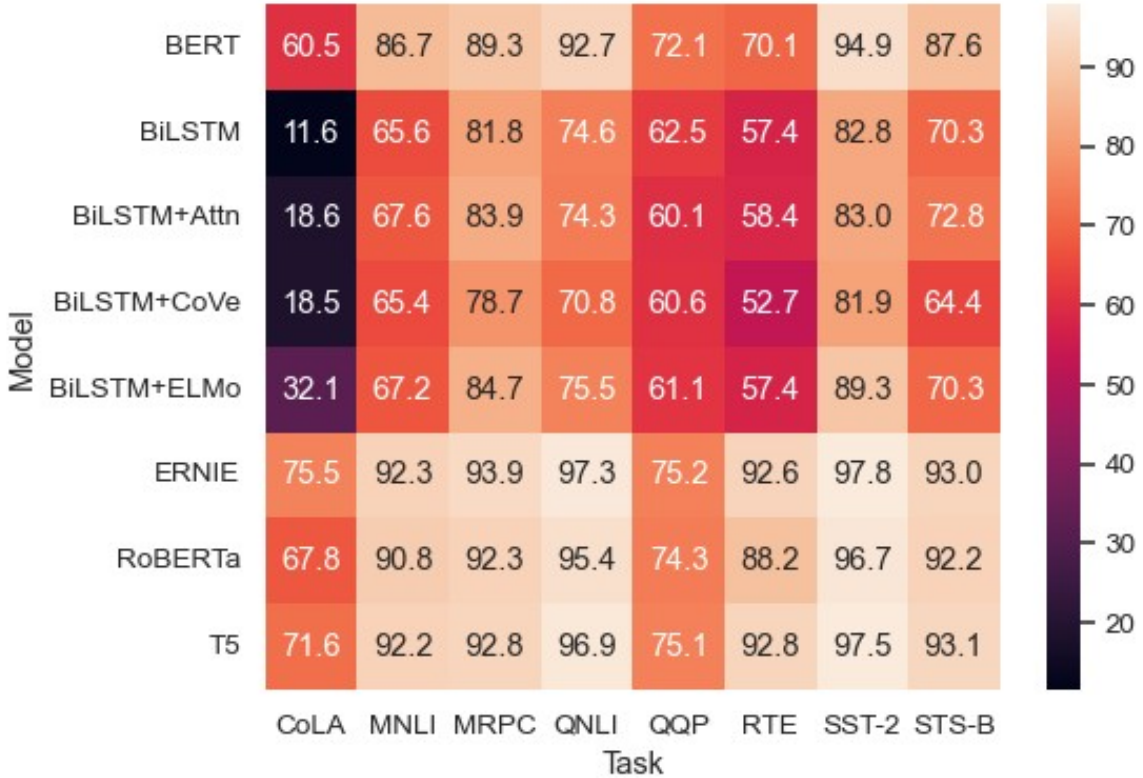

Źródło: https://seaborn.pydata.org/generated/seaborn.heatmap.html

Brakujące dane

Metoda postępowania w przypadku brakujących danych będzie w dużym stopniu zależała od ich rodzaju i zakresu. Bardzo często będzie to również mieszanka różnych podejść:

- Ignorowanie (w przypadku, gdy ilość brakujących danych jest znikoma i wykorzystywane metody na to pozwalają)
- Usuwanie danych (jeśli brakujące wartości są losowe, a zbiór danych jest na tyle duży, że brakujące punkty danych nie mają na nie wpływu)
- Wstawianie wartości (przy użyciu średniej, mediany, mode dla rozkładów normalnych lub przekoszonych, resp w odniesieniu do danych kategorycznych, etc.)

Brakujące dane

Po obsłużeniu brakujących danych ważne jest, aby ocenić, jaki wpływ mają one na zbiór danych.

Możemy na przykład porównać statystyki podsumowujące przed i po obsłużeniu brakujących danych.

Dodatkowo możemy użyć funkcji hist() lub boxplot() do porównania rozkładu i wartości odstających kolumn, corr() lub scatterplot() do porównania korelacji i relacji zmiennych oraz funkcji score() lub cross_val_score() do porównania dokładności i wydajność modeli.

Brakujące dane

Cały proces należy udokumentować!

Podczas obsługi brakujących danych kluczową cechą jest kontekst – czasami możemy uzyskać cenne spostrzeżenia na podstawie brakujących danych, a także pozostałego zbioru danych. Musimy zatem rozważyć, co brakujące dane mogą nam powiedzieć o projekcie.

Przetwarzanie równoległe

Przetwarzanie równoległe polega na podzieleniu zbioru danych na mniejsze części i rozdzieleniu przetwarzania na wiele maszyn lub procesorów. Może to znacznie zwiększyć szybkość i efektywność analizy dużych zbiorów danych.

Przetwarzanie równoległe

Gdy zadania są wykonywane sekwencyjnie, program musi poczekać na zakończenie jednego zadania, zanim przejdzie do następnego. Może to prowadzić do marnowania czasu, szczególnie jeśli niektóre zadania są niezależne i nie trzeba czekać na zakończenie innych.

Przy przetwarzaniu równoległym zadania są dzielone i przydzielane różnym procesorom. Każdy procesor pracuje równolegle nad przydzielonym mu zadaniem, skracając w ten sposób całkowity czas jego wykonania. Jest to szczególnie korzystne w programach, w których zadania są niezależne i mogą być przetwarzane jednocześnie.

Przetwarzanie równoległe

Dzięki przetwarzaniu równoległemu zadania są realizowane szybciej i wymagają mniej zasobów obliczeniowych. Krótszy czas przetwarzania oznacza, że zasoby są szybciej zwalniane na inne zadania. Ta zwiększona wydajność może przełożyć się na oszczędności.

Ponadto przetwarzanie równoległe może prowadzić do lepszego wykorzystania istniejących zasobów. Dzięki rozłożeniu obciążenia obliczeniowego na wiele procesorów każdy procesor jest wykorzystywany w maksymalnym stopniu. Może to zmniejszyć zapotrzebowanie na dodatkowe zasoby, co prowadzi do oszczędności.

Przetwarzanie równoległe - Python

Multi-threading

Wielowątkowość jest formą przetwarzania równoległego, która umożliwia programowi wykonywanie wielu zadań jednocześnie.

W Pythonie moduł **threading** umożliwia tworzenie wątków i zarządzanie nimi. Każdy wątek może uruchamiać określoną funkcję lub metodę, a wszystkie wątki działają niezależnie od siebie.

Przetwarzanie równoległe - Python

Multi-threading

Ze względu na globalną blokadę interpretera (GIL) w Pythonie wielowątkowość nie zawsze prowadzi wprost do wzrostu wydajności. GIL to mechanizm, który uniemożliwia wielu natywnym wątkom jednoczesne wykonywanie kodów bajtowych Pythona.

Oznacza to, że nawet w systemie wieloprocesorowym wątki nie będą działać równolegle. Jednak wielowątkowość może być nadal korzystna w przypadku zadań związanych z operacjami I/O, gdzie program spędza większość czasu czekając na operacje wejścia/wyjścia.

Przetwarzanie równoległe - Python

Multiprocessing

Przetwarzanie wieloprocesowe to kolejna forma przetwarzania równoległego, która polega na jednoczesnym uruchamianiu wielu procesów.

W Pythonie moduł **multiprocessing** umożliwia tworzenie procesów i zarządzanie nimi. W przeciwieństwie do wątków, każdy proces działa we własnym interpreterze Pythona, co oznacza, że mogą działać równolegle w systemie wieloprocesorowym.

Przetwarzanie równoległe - Python

Multiprocessing

Moduł multiprocessing zapewnia możliwość udostępniania danych między procesami, chociaż może to być bardziej złożone niż udostępnianie danych między wątkami.

Przetwarzanie wieloprocesowe jest świetnym sposobem na zwiększenie wydajności zadań związanych z procesorem, gdzie program spędza większość czasu na wykonywaniu obliczeń.

Przetwarzanie równoległe - Python

Programowanie asynchroniczne

Programowanie asynchroniczne to forma programowania współbieżnego, która polega na wykonywaniu zadań w sposób nieblokujący.

W Pythonie moduł **asyncio** umożliwia pisanie kodu asynchronicznego. Dzięki asyncio można napisać kod, który wykonuje zadania związane z operacjami we/wy, bez blokowania wykonywania reszty programu.

Przetwarzanie równoległe - Python

Programowanie asynchroniczne

Programowanie asynchroniczne może być bardziej złożone niż wielowątkowość lub wieloprocesorowość, ponieważ wymaga innego sposobu myślenia o przepływie programu. Jednakże może to być potężne narzędzie do pisania wydajnego kodu o wysokiej wydajności, szczególnie w przypadku zadań związanych z operacjami wejścia-wyjścia.

MapReduce

MapReduce to model programowania przeznaczony do przetwarzania danych na dużą skalę. Polega na podzieleniu przetwarzania na dwie fazy: fazę „mapowania”, w której dane przetwarzane są równolegle, oraz fazę „redukcji”, w której agregowane są wyniki.

MapReduce

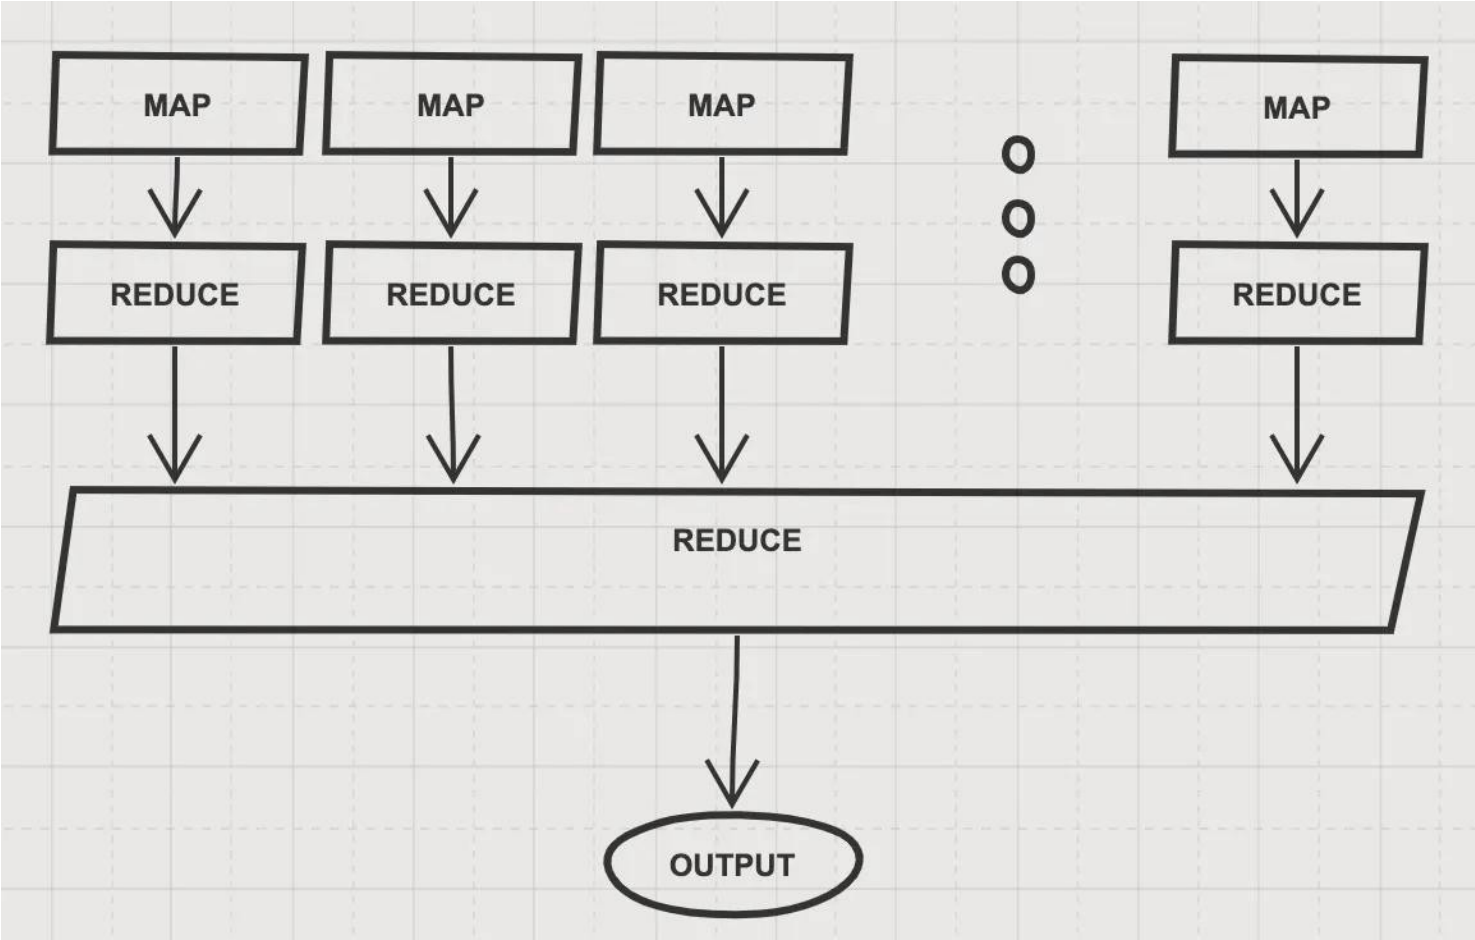

Źródło: https://towardsdatascience.com/a-beginners-introduction-into-mapreduce-2c912bb5e6ac

Uczenie Maszynowe

Algorytmy uczenia maszynowego mogą służyć do automatycznego identyfikowania wzorców i trendów w dużych zbiorach danych. Algorytmy te można trenować na podzbiorze danych, a następnie stosować do reszty zbioru w celu przewidywania wartości lub podejmowania decyzji.

Wizualizacja

Techniki wizualizacji, można wykorzystać do eksploracji danych w celu lepszego zrozumienia dużych zbiorów danych.

Wizualizacja może pomóc w zidentyfikowaniu wzorców i trendów, które mogą nie być widoczne w surowych danych.

Eksploracja danych ogólnie

Ogólnie rzecz biorąc, wybór metody eksploracji zależy w dużym stopniu od charakterystyki zbioru danych i celów projektu.

Ważne jest, aby jak najwcześniej jak najlepiej poznać analizowany problem/rozwiązywane zadanie.

Eksploracja danych wymaga czasu i proces ten należy udokumentować.

Dyskusja 2

1. System rozpoznawania twarzy do identyfikacji pracowników w budynku firmy
2. System klasyfikacji obrazu ułatwiający wykrywanie raka
3. System analizy potrzeb/reklamacji klientów oparty na sztucznej inteligencji

Dla którego z nich zebranie/przygotowanie danych byłoby najtrudniejsze? Dla którego będzie najłatwiejsze?

Dlaczego?

GRUPOWANIE

Grupowanie

Grupowanie polega na wykorzystaniu technik bez nadzoru do oznaczenia podobnych obiektów.

W uczeniu maszynowym określenie „bez nadzoru” odnosi się do problemu znalezienia ukrytych wzorców w nieoznaczonych danych.

Wzorce w danych opisują interesujące nas obiekty i określają, w jaki sposób najlepiej je pogrupować.

Grupowanie

Grupowanie jest często stosowane do eksploracji danych. Nie służy ono do prognozowania. Metody grupowania wyszukują podobieństwa między obiektami na podstawie atrybutów.

Techniki grupowania są wykorzystywane w marketingu, ekonomii i różnych gałęziach nauki.

Popularną metodą grupowania jest metoda k-średnich.

Algorytm K-średnich

Mając zbiór obiektów, z których każdy ma n mierzalnych atrybutów, metoda k-średnich jest techniką analityczną, która dla wybranej wartości identyfikuje k skupisk obiektów na podstawie ich bliskości do środka k grup.

Środek wyznacza się jako średnią arytmetyczną n-wymiarowego wektora atrybutów każdego skupienia.

Algorytm K-średnich

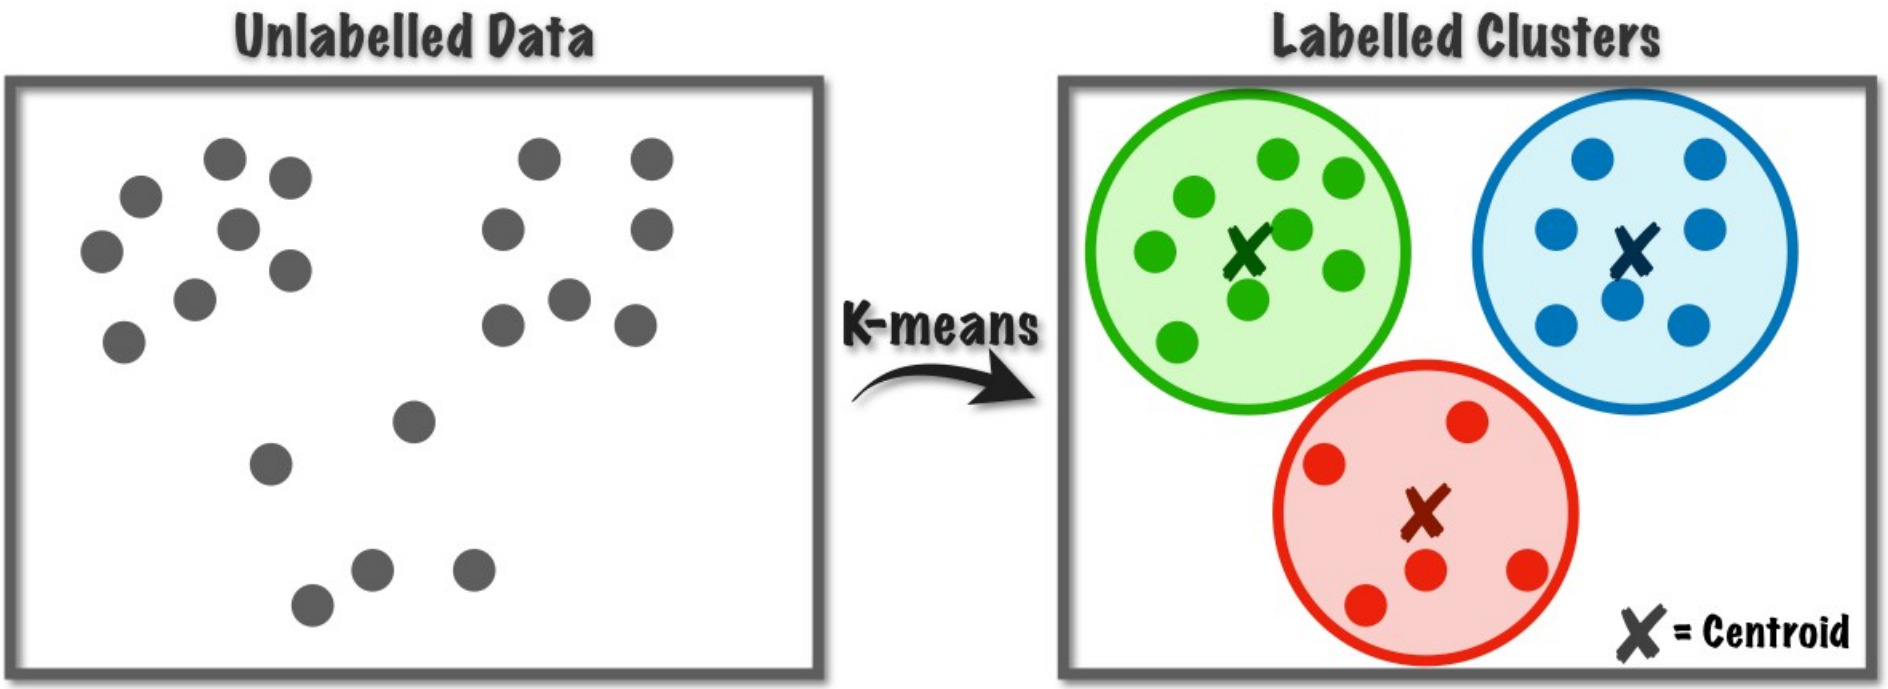

Source: https://miro.medium.com/v2/resize:fit:1200/1*rw8IUza1dbffBhiA4i0GNQ.png

Algorytm K-średnich - zastosowania

Przetwarzanie obrazów

Wideo jest jednym z przykładów szybko rosnących, nieustrukturyzowanych danych. Można tu zastosować analizę k-średnich do identyfikacji obiektów. Dla każdej klatki określamy, które piksele są do siebie najbardziej podobne. Atrybuty piksela mogą obejmować jasność, kolor i lokalizację, a także współrzędne x i y w ramce.

W przypadku obrazów wideo z monitoringu sprawdzane są kolejne klatki w celu zidentyfikowania zmian w klastrach. Te nowo zidentyfikowane skupiska mogą wskazywać na nieautoryzowany dostęp do obiektu.

Algorytm K-średnich - zastosowania

Medycyna

Cechy pacjenta, takie jak wiek, wzrost, masa ciała, ciśnienie krwi, poziom cholesterolu i inne mogą identyfikować naturalnie występujące skupiska. Klastry te można wykorzystać do skierowania osób do specjalisty lub na badania kliniczne.

Grupowanie jest przydatne w biologii do klasyfikacji roślin i zwierząt, a także w dziedzinie genetyki człowieka.

Algorytm K-średnich - zastosowania

Segmentacja klientów

Grupy marketingowe i sprzedażowe wykorzystują grupowanie k-średnich, aby lepiej identyfikować klientów o podobnych zrachowaniach. Na przykład dostawca usług bezprzewodowych może sprawdzić następujące atrybuty klienta: miesięczny rachunek, liczbę wiadomości tekstowych, ilość zużytych danych, minuty wykorzystane w różnych okresach dnia oraz lata bycia klientem. Firma mogłaby następnie przyjrzeć się klastrom i rozważyć taktykę mającą na celu zwiększenie sprzedaży lub zmniejszenie ilości odchodzących klientów.

Algorytm K-średnich - działanie

1. Wybierz wartość k i k początkowych położeń cetroidów.
2. Oblicz odległość od punktu danych do każdej centroidy. Przypisz punkt do najbliższej centroidy. To powiązanie definiuje pierwsze k klastrów.
3. Oblicz środek masy każdego nowo zdefiniowanego klastra z kroku 2.
4. Powtarzaj kroki 2 i 3, aż algorytm zakończy działanie.

Algorytm K-średnich - działanie

Wartość k można wybrać na podstawie przypuszczenia lub z góry określonego wymagania. Po wyborze można sprawdzić o ile lepsze lub gorsze byłoby posiadanie k klastrów w porównaniu z klastrami k – 1 lub k + 1.

Zwykle dla tej metryki używalibyśmy sumy kwadratów odległości (WSS) pomiędzy każdym punktem danych a najbliższym środkiem ciężkości. Jeśli punkty znajdują się blisko swoich centroid, parametr będzie miał małe wartości. Zatem, jeśli klastry k + 1 nie zmniejszą znacząco wartości WSS, dodanie kolejnego klastra przynosi niewielkie korzyści.

Algorytm K-średnich - działanie

Ogólnie należy rozważyć następujące kwestie:

- Czy klastry są dobrze od siebie oddzielone?
- Czy któreś z klastrów ma tylko kilka punktów?
- Czy któreś z centroidów wydają się znajdować zbyt blisko siebie?

Algorytm K-średnich - działanie

Ponieważ metoda nie wymaga nadzoru, użycie k-średnich pomaga wyeliminować subiektywizm z analizy.

Chociaż metoda k-średnich jest metodą nienadzorowaną, musimy podjąć kilka decyzji na starcie:

- Jakie atrybuty uwzględnić w analizie?
- Jaką jednostkę miary (na przykład mile lub kilometry) należy zastosować w przypadku każdego atrybutu?
- Czy należy przeskalować atrybuty?
- Jakie inne parametry/problemy należy uwzględnić/rozwiązać?

Algorytm K-średnich - parametry

Ważne jest, aby zrozumieć, jakie atrybuty będą znane w momencie dodawania nowych obiektów do zbioru danych.

Na przykład informacje na temat zadowolenia obecnych klientów lub częstotliwości zakupów mogą być dostępne, ale niekoniecznie będzie tak dla nowych klientów, których dopiero chcemy pozyskać.

Algorytm K-średnich - parametry

Gdy jest to możliwe zawsze warto spróbować zredukować liczbę atrybutów.

Zbyt wiele atrybutów może zminimalizować wpływ najważniejszych zmiennych. Użycie kilku podobnych atrybutów może przypisać zbyt dużą wagę do jednego typu atrybutu.

Na przykład, jeśli w analizie skupień uwzględni się pięć atrybutów związanych z majątkiem osobistym, mogą one zamaskować znaczenie innych atrybutów, takich jak wiek.

Algorytm K-średnich - parametry

Jeśli mamy wiele atrybutów, przydatne może być zidentyfikowanie tych wysoce skorelowanych i użycie tylko jednego lub dwóch z nich.

Wykres rozrzutu (ang. Scatterplot) jest użytecznym narzędziem do wizualizacji relacji pomiędzy atrybutami.

Inną możliwością zmniejszenia liczby atrybutów jest połączenie kilku atrybutów w jedną miarę. Na przykład zamiast używać dwóch zmiennych atrybutów A i B, można zastosować stosunek A do B. Ta opcja rozwiązuje również problem, gdy sama wielkość atrybutu nie jest istotna, ale jest tak w przypadku jego wielkości względnej.

Algorytm K-średnich – jednostki miary

Z obliczeniowego punktu widzenia algorytm k-średnich jest obojętny na jednostki miary dla danego atrybutu. Algorytm będzie jednak identyfikował różne skupienia w zależności od wyboru jednostek miary.

Algorytm K-średnich – jednostki miary

Załóżmy że używamy algorytmu k-średnich do grupowania pacjentów na podstawie wieku i wzrostu. Zakładając, że wiek jest podany w latach, wynikowa grupa będzie różna, w zależności od jednostki użytej do określenia wzrostu (metry lub centymetry) – jeśli wzrost jest podany w metrach, lat będą dominować przy obliczaniu odległości między punktami.

Atrybut wysokości doda kwadrat pomiędzy różnicą maksymalnego i minimalnego wzrostu (2,0 – 0)2 = 4. Dla wieku ten przedział będzie o wiele większy, np.: (80 – 0)2 = 6400.

Algorytm K-średnich – skalowanie wartości

Atrybuty wyrażone w walutach są powszechne w analizach skupień i mogą różnić się wielkością od innych atrybutów. Na przykład, jeśli dochód osobisty jest wyrażony w dolarach, a wiek w latach, atrybut dochodu może z łatwością zdominować obliczanie odległości pomiędzy przykładami, przy wieku zwykle nieprzekraczającym 100 lat.

Aby poprawić sytuację, możemy podzielić każdy atrybut przez jego odchylenie standardowe. Każdy wynikowy atrybut będzie miał odchylenie standardowe równe 1 i będzie pozbawiony jednostek.

Algorytm K-średnich – skalowanie wartości

W wielu analizach statystycznych często przekształca się typowo wypaczone dane, takie jak dochody, z dużym rozrzutem wartości, przyjmując logarytm danych.

Taką transformację można również zastosować w k-średnich, ale analityk danych musi mieć świadomość, jak wpływ będzie miała ta transformacja.

Na przykład, jeśli stosuje się log10 dochodu wyrażonego w dolarach, zasadniczo stwierdzamy, że z perspektywy grupowania 1000 dolarów jest tak bliskie 10 000 dolarów jak 10 000 dolarów ma się do 100 000 dolarów (ponieważ log101000=3; log1010000=4 i log10100,000=5).

Algorytm K-średnich

Algorytm k-średnich jest wrażliwy na pozycje początkowe środków ciężkości. Ważne jest, aby kilkakrotnie powtórzyć analizę k-średnich dla określonej wartości k, aby upewnić się, że wyniki zapewniają ogólny minimalny WSS.

Do pomiaru odległości, oprócz odległości euklidesowej, można wybrać inne funkcje, takie jak cosine similarity i funkcja odległości Manhattan.

Algorytm K-średnich

Cosine similarity - jest często wybierana do porównywania dwóch dokumentów na podstawie częstotliwości występowania każdego słowa.

Odległość Manhattan jest analogiczna do odległości przebytej przez samochód w mieście, w którym ulice są ułożone w prostokątną siatkę (również nazywana metryką miejską).

Algorytm K-średnich

Grupowanie K-średnich ma zastosowanie do obiektów, które można opisać za pomocą atrybutów liczbowych i miarą odległości.

Nie radzi sobie dobrze ze zmiennymi kategorycznymi. W takich przypadkach może być konieczne zastosowanie alternatywnej metody grupowania.

Rodzaje algorytmów grupujących

Oparte na gęstości

Grupują dane według obszarów o dużej koncentracji punktów danych.

Algorytm znajduje miejsca gęste z punktami danych i oznacza je jako klastry.

Klastry mogą mieć dowolny kształt.

Wartości odstające są ignorowane.

Rodzaje algorytmów grupujących

Oparta na dystrybucji

Grupowanie opiera się na prawdopodobieństwie, że punkt danych należy do danego klastra.

Im dalej punkt znajduje się od środka skupienia danych, tym mniejsze jest prawdopodobieństwo, że należy on do tego skupienia.

Jeśli nie wiadomo jak wygląda dystrybucja danych w zbiorze danych, zastosowanie algorytmów z tej grupy nie jest najlepszym podejściem.

Rodzaje algorytmów grupujących

Oparty na centroidach

Do tej grupy należy algorytm k-średnich.

Punkty danych są rozdzielane na podstawie wielu centroid w danych i przypisywane do klastra poprzez obliczenie kwadratowej odległości od środka ciężkości.

Wrażliwe na parametry startowe.

Rodzaje algorytmów grupujących

Oparte na hierarchii

Zwykle używane w przypadku danych hierarchicznych (np. z bazy danych firmy lub taksonomii).

Algorytm buduje drzewo klastrów, organizując wszystko zstępująco.

Bardziej restrykcyjne niż inne typy grupowania, ale idealne do zastosowań z tej grupy.

Przykładowe metody

- DBSCAN
- Gaussian Mixture Model
- BIRCH
- Affinity propagation
- Mean-Shift
- OPTICS
- Agglomerative Hierarchy
- Divisive Hierarchical
- Mini-Batch K-means
- Spectral Clustering

Uwagi ogólne

Możemy użyć grupowania, aby uzyskać dodatkowy wgląd w nasze dane.

Chociaż grupowanie jest problemem uczenia bez nadzoru, wyniki można wykorzystać w uczeniu nadzorowanym, a powstałe klastry stanowią etykiety danych.

Klastry można również wykorzystać jako elementy danych w nowym zbiorze danych.

Musimy przeanalizować wyniki!

REGUŁY ASOCJACJI

Reguły asocjacji

Opisowa metoda uczenia się bez nadzoru, często używana do odkrywania relacji ukrytych w dużym zbiorze danych.

Relacje można przedstawić w postaci reguł lub częstych zbiorów pozycji. Reguły asocjacyjne są powszechnie używane do wyszukiwania transakcji w bazach danych.

Reguły asocjacji

Najczęstsze pytania, na które staramy się odpowiedzieć za pomocą tej metody:

- Które produkty są najczęściej kupowane razem?
- Z naszych klientów – którzy są podobni do wybranej osoby, jakie produkty najchętniej kupują?
- Spośród naszych klientów – którzy kupili ten produkt, jakie inne podobne produkty najczęściej przeglądają lub kupują?

Reguły asocjacji

Biorąc pod uwagę duży zbiór transakcji, w których każda transakcja składa się z jednego lub większej liczby pozycji, reguły asocjacji sprawdzają kupowane pozycje, aby zobaczyć, jakie pozycje są często kupowane razem i odkryć listę reguł opisujących zachowania.

Celem jest odkrycie interesujących relacji pomiędzy elementami. Interesujące relacje zależą zarówno od kontekstu biznesowego, jak i charakteru algorytmu użytego do odkrycia.

Reguły asocjacji

Każda z odkrytych reguł ma postać $X \rightarrow Y$.

Korzystając z reguł asocjacyjnych, na podstawie danych można odkryć wzorce, które pozwalają ujawnić zakupy powiązanych produktów.

Reguły asocjacyjne są czasami określane jako analiza koszykowa.

Algorytm Apriori

Apriori jest jednym z najwcześniejszych i najbardziej podstawowych algorytmów generowania reguł asocjacyjnych. Zestawy elementów, o których wiadomo, że występują często, są łączone i przycinane w celu wygenerowania dłuższych, częstych zestawów elementów.

Jednym z głównych elementów Apriori jest parametr support (wsparcie). Biorąc pod uwagę zestaw pozycji L, wsparcie dla L jest procentem transakcji zawierających L. Jeśli 80% wszystkich transakcji zawiera {chleb}, wówczas wsparcie dla {chleb} wynosi 0,8.

Algorytm Apriori

Zestaw częstych przedmiotów zawiera elementy, które wystarczająco często pojawiają się razem. Termin „wystarczająco często” jest formalnie zdefiniowany za pomocą kryterium minimalnego wsparcia. Jeśli minimalne wsparcie jest ustawione na 0.5, każdy zestaw przedmiotów można uznać za częsty, jeśli zawiera go co najmniej 50% transakcji.

Innymi słowy, wsparcie częstego zestawu przedmiotów powinno być większe lub równe wsparciu minimalnemu.

Algorytm Apriori

Jeśli zestaw elementów jest uważany za częsty, wówczas każdy podzbiór również musi być częsty. Nazywa się to właściwością Apriori (lub właściwością zamknięcia w dół).

Na przykład, jeśli 60% transakcji zawiera {chleb, dżem}, to co najmniej 60% wszystkich transakcji będzie zawierać {chleb} lub {dżem}.

Algorytm Apriori

Zestawy przedmiotów, które nie spełniają minimalnego progu wsparcia, są usuwane.

Proces rozrastania i usuwania zbioru elementów częstych jest powtarzany dla co raz dłuższych zestawów, aż żaden nie osiągnie minimalnego progu wsparcia. Opcjonalnie można ustawić próg, aby określić maksymalną liczbę elementów, lub maksymalną liczbę iteracji algorytmu.

Po zakończeniu wynikiem algorytmu Apriori jest zbiór wszystkich częstych zbiorów do k-elementowych.

Algorytm Apriori

Następnie tworzony jest zbiór reguł kandydujących w oparciu o częste zestawy pozycji.

Na przykład częsty zestaw pozycji {mleko, jajka} może przełożyć się na zasady {mleko} → {jaja} i {jajka} → {mleko}.

Ocena reguł - confidence

Confidence definiuje się jako miarę pewności lub wiarygodności związaną z każdą odkrytą regułą.

Matematycznie pewność to procent transakcji zawierających zarówno X, jak i Y spośród wszystkich transakcji zawierających X

$$Confidence(X \rightarrow Y \ni \quad \frac{Support(X \wedge Y)}{Support(X)}$$

Ocena reguł - confidence

Zależność można uznać za interesującą, gdy algorytm zidentyfikuje ją z miarą pewności większą lub równą wcześniej określonemu progowi.

Ten wstępnie zdefiniowany próg nazywany jest minimalnym poziomem ufności.

Większa pewność wskazuje, że reguła ($X \rightarrow Y$) jest bardziej interesująca lub bardziej wiarygodna na podstawie przykładowego zbioru danych.

Ocena reguł - confidence

Za pomocą tej miary nie może stwierdzić, czy reguła zawiera prawdziwe implikacje związku, czy też reguła jest czysto przypadkowa.

X i Y mogą być statystycznie niezależne, a mimo to uzyskać wysoki wynik pewności

Ocena reguł - lift

Wzrost mierzy, ile razy częściej X i Y występują razem, niż oczekiwano, jeśli są od siebie statystycznie niezależne.

Wzrost jest miarą tego, czy X i Y są naprawdę powiązane:

$$Lift(X \rightarrow Y) = \frac{Support(X \wedge Y)}{Support(X) * Support(Y)}$$

Ocena reguł - lift

Wzrost wynosi 1, jeśli X i Y są od siebie statystycznie niezależne. Natomiast wzrost X → Y większy niż 1 wskazuje zależność między nimi.

Większa wartość zmiennej lift sugeruje większą siłę powiązania między X i Y.

Ocena reguł - leverage

Leverage jest podobnym pojęciem, ale zamiast używać współczynnika, wykorzystuje różnicę.

Lift mierzy różnicę w prawdopodobieństwie wystąpienia X i Y razem w zbiorze danych w porównaniu z tym, czego można by się spodziewać, gdyby X i Y były od siebie statystycznie niezależne.

$$Leverage(X \rightarrow Y) = Support(X \wedge Y) - Support(X) * Suppoort(Y)$$

Ocena reguł – inne miary

Oprócz czterech omówionych miar istnieją również alternatywne podejścia:

- Korelacja
- Zbiorowa siła (collective strength)
- conviction
- coverage

Walidacja i testowanie

Po zebraniu reguł wyjściowych może okazać się konieczne zastosowanie jednej lub większej liczby metod w celu sprawdzenia poprawności wyników w kontekście biznesowym dla przykładowego zbioru danych.

Pierwsze podejście można ustalić za pomocą miar statystycznych. Reguły obejmujące wzajemnie niezależne pozycje lub obejmujące kilka transakcji są uważane za nieinteresujące, ponieważ mogą uchwycić fałszywe relacje

Walidacja i testowanie

Inny zestaw kryteriów można ustalić na podstawie subiektywnych argumentów. Nawet przy dużej pewności reguła może zostać uznana za nieinteresującą, chyba że ujawni nieoczekiwane zyskowne działania.

Na przykład reguły takie jak {papier} → {ołówek} mogą nie być subiektywnie interesujące lub znaczące pomimo wysokich wartości wsparcia i pewności.

Z kolei reguła taką jak {pieluszka} → {piwo}, można uznać za subiektywnie interesującą, ponieważ jest ona nieoczekiwana i może sugerować potencjał sprzedaży krzyżowej.

Diagnostyka

Algorytm Apriori zmniejsza obciążenie obliczeniowe, badając jedynie zestawy elementów, które spełniają określone minimum.

W zależności od rozmiaru zbioru danych algorytm Apriori ciągle może być kosztowny obliczeniowo.

Dla każdego poziomu wsparcia algorytm wymaga przeskanowania całej bazy danych, aby uzyskać wynik. W związku z tym w miarę powiększania się bazy danych obliczenia zajmują więcej czasu.

Diagnostyka

Przykładowe podejścia poprawiające wydajność:

Partycjonowanie: Każdy zestaw pozycji, który jest potencjalnie częsty w bazie danych transakcji, musi być częsty w co najmniej jednej z partycji bazy danych transakcji.

Próbkowanie: wyodrębnia podzbiór danych z niższym progiem wsparcia i wykorzystuje ten podzbiór do eksploracji reguł asocjacyjnych.

Redukcja transakcji: Transakcja, która nie zawiera częstych zestawów k-elementów, jest bezużyteczna w kolejnych skanach i dlatego można ją zignorować.

Diagnostyka

Przykładowe podejścia poprawiające wydajność:

Liczenie zestawów elementów w oparciu o skrót: Jeśl liczba segmentów zestawu k-elementów jest poniżej pewnego progu, zestaw k-elementów nie może być częsty.

Dynamiczne liczenie zestawów elementów: dodawaj nowe zestawy elementów kandydujących tylko wtedy, gdy szacuje się, że wszystkie ich podzbiory są częste.

Uwagi ogólne

Jako technika analizy nienadzorowanej, która odkrywa relacje między elementami, reguły asocjacji znajdują wiele zastosowań, w tym w analizie koszyka rynkowego, analizie strumienia kliknięć i silnikach rekomendujących.

Chociaż reguły asocjacji nie są używane do przewidywania wyników lub zachowań, dobrze sprawdzają się w identyfikowaniu „interesujących” relacji w obrębie pozycji z dużego zbioru danych.

Uwagi ogólne

Algorytm Apriori jest jednym z najwcześniejszych i najbardziej podstawowych algorytmów reguł asocjacyjnych.

Miary takie jak wsparcie, zaufanie, wzrost (lift), leverage inne powinny być wykorzystywane przy ewaluacji. Razem pomagają zidentyfikować interesujące reguły i wyeliminować te przypadkowe.

W przypadku dużych zbiorów danych algorytm może wymagać optymalizacji.

REGRESJA

Regresja

Regresja ma na celu wyjaśnienie wpływu zestawu zmiennych na wynik innej zmiennej.

Zmienną wynikową nazywa się **zmienną zależną**. Zmienne wykorzystywane w predykcji nazywamy **zmiennymi wejściowymi** lub **zmiennymi niezależnymi**.

Regresja

Regresja jest przydatna do odpowiadania na następujące rodzaje pytań:

- Jaki jest oczekiwany dochód danej osoby?
- Jakie jest prawdopodobieństwo, że wnioskodawca nie spłaci pożyczki?

Regresja jest użytecznym narzędziem wyjaśniającym, które pozwala zidentyfikować zmienne wejściowe, mające największy wpływ statystyczny na wynik.

Regresja liniowa

Regresja liniowa to technika analityczna stosowana do modelowania związku między kilkoma zmiennymi wejściowymi a ciągłą zmienną wynikową.

Kluczowym założeniem jest to, że związek między zmienną wejściową a zmienną wynikową jest liniowy.

Chociaż jest to do pewnego stopnia restrykcyjne, często możliwe jest przekształcenie zmiennych wejściowych lub wynikowych w celu uzyskania liniowej zależności.

Regresja liniowa

Regresja liniowa jest często stosowana w scenariuszach biznesowych, rządowych i innych. Niektóre typowe praktyczne zastosowania obejmują:

Nieruchomości: Do modelowania cen domów mieszkalnych. Taki model pomaga oszacować cenę katalogową domu na rynku. Model można ulepszyć poprzez uwzględnienie różnych zmiennych wejściowych, takich jak liczba łazienek, liczba sypialni, wielkość działki, rankingi okręgów szkolnych, statystyki przestępczości i podatki od nieruchomości.

Regresja liniowa

Prognozowanie popytu: można wykorzystać modele regresji liniowej do przewidywania popytu na towary i usługi. Na przykład sieci restauracji mogą odpowiednio przygotować się na przewidywany rodzaj i ilość jedzenia, w zależności od pogody, dnia tygodnia, tego, czy dana pozycja jest oferowana jako oferta specjalna, pory dnia i wielkości rezerwacji. Podobne modele można zbudować w celu przewidywania sprzedaży detalicznej, wizyt na izbie przyjęć i wysyłania karetek.

Regresja liniowa

Medycyna: np. analiza wpływu proponowanej radioterapii na zmniejszenie rozmiarów guza - można zastosować model regresji liniowej. Zmienne wejściowe mogą obejmować czas trwania pojedynczej radioterapii, jej częstotliwość oraz cechy pacjenta, takie jak wiek lub waga.

Regresja liniowa

Załóżmy, że chcemy zbudować model regresji liniowej, który szacuje roczny dochód danej osoby jako funkcję dwóch zmiennych – wieku i wykształcenia – wyrażonych w latach. W tym przypadku zmienną wynikową jest dochód, a zmiennymi wejściowymi są wiek i wykształcenie.

Regresja liniowa

Chociaż jest to ogólny przypadek, taki model wydaje się intuicyjnie poprawny w tym sensie, że dochody ludzi powinny rosnąć wraz z wiekiem oraz wzrostem ich umiejętności i doświadczenia. Oczekuje się również, że początkowe możliwości zatrudnienia i wynagrodzenia będą większe w przypadku osób, które uzyskały wyższe wykształcenie.

Regresja liniowa

Oczywiste jest również, że istnieje duże zróżnicowanie w poziomie dochodów grupy osób o identycznym wieku i latach wykształcenia. Jest to reprezentowane przez ε w modelu. W tym przypadku model wygląda następująco:

$$Income = \beta_0 + \beta_1 Age + \beta_2 Education + \varepsilon$$

W modelu liniowym β_i reprezentuje nieznane parametry p. Wartości dla tych nieznanych parametrów dobiera się tak aby średnio model zapewniał rozsądne oszacowanie dochodu danej osoby na podstawie wieku i wykształcenia.

Regresja liniowa

Celem jest znalezienie najlepszej linii, która przybliża relację między punktami danych.

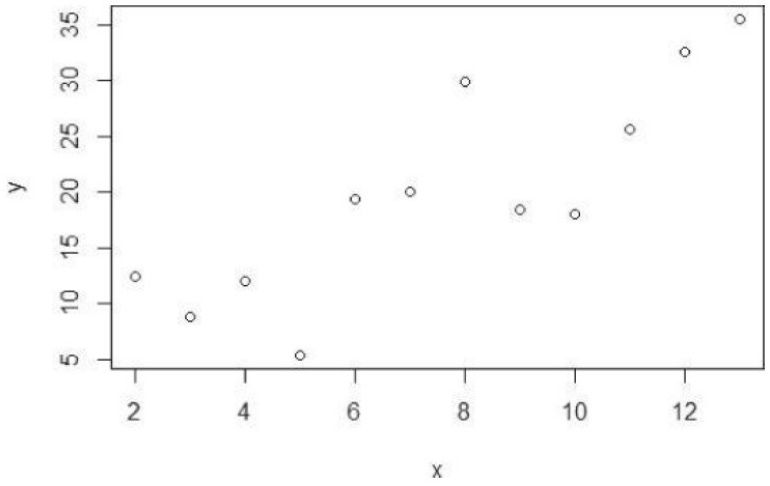

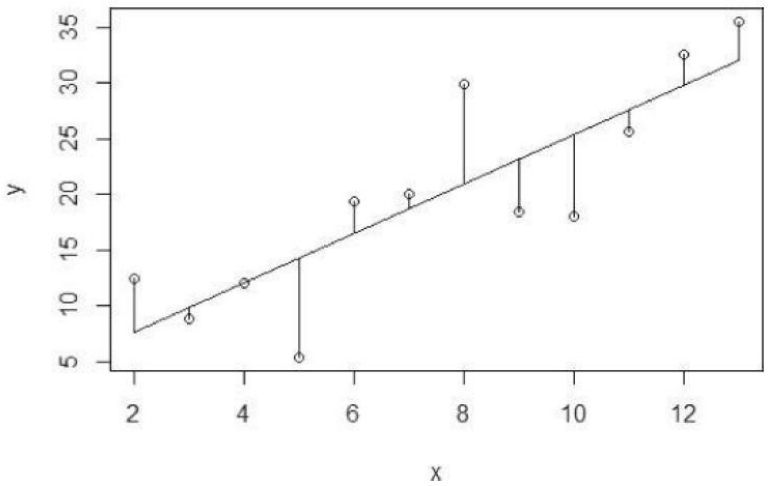

W większości przypadków regresji liniowej przyjmuje się, że składnik błędu jest zmienną losową o rozkładzie normalnym, ze średnią równą zero i stałą wariancją.

Regresja liniowa - ewaluacja modelu

Resztkowy błąd standardowy (residual standard error) to odchylenie standardowe zaobserwowane dla wartości resztkowych. Wartość tę wraz z powiązanymi stopniami swobody można wykorzystać do zbadania wariancji założonych składników błędu o rozkładzie normalnym.

Regresja liniowa - ewaluacja modelu

Wartość R2 można zwiększyć, dodając do modelu więcej zmiennych.

Samo dodanie większej liczby zmiennych w celu wyjaśnienia zbioru danych, ale nie w celu poprawy charakteru modelu, określamy przetrenowaniem modelu. Aby uwzględnić możliwość nadmiernego dopasowania danych, skorygowany R2 uwzględnia liczbę parametrów w modelu regresji liniowej.

Regresja liniowa - ewaluacja modelu

Statystyka F zapewnia metodę testowania całego modelu regresji. W poprzednich testach t przeprowadzono indywidualne testy w celu określenia istotności statystycznej każdego parametru.

Regresja liniowa

Czasami chcielibyśmy uwzględnić w modelu zmienne kategoryczne, ale samo przypisanie liczb, zwykle nie będzie dobrze działać.

W regresji właściwym sposobem implementacji zmiennej kategorycznej, która może przyjmować m różnych wartości, jest dodanie m-1 zmiennych binarnych do modelu regresji.

Regresja liniowa – diagnostyka modelu

Założenie liniowości

Głównym założeniem w modelowaniu regresji liniowej jest to, że związek między zmiennymi wejściowymi a zmienna wynikową jest liniowy. Najbardziej podstawowym sposobem oceny takiej zależności jest stworzenie wykresu dla zmiennej wynikowej względem każdej zmiennej wejściowej.

Regresja liniowa – diagnostyka modelu

Założenie liniowości – przykładowe wykresy punktowe, założenie to jest spełnione dla dochodu i wieku.

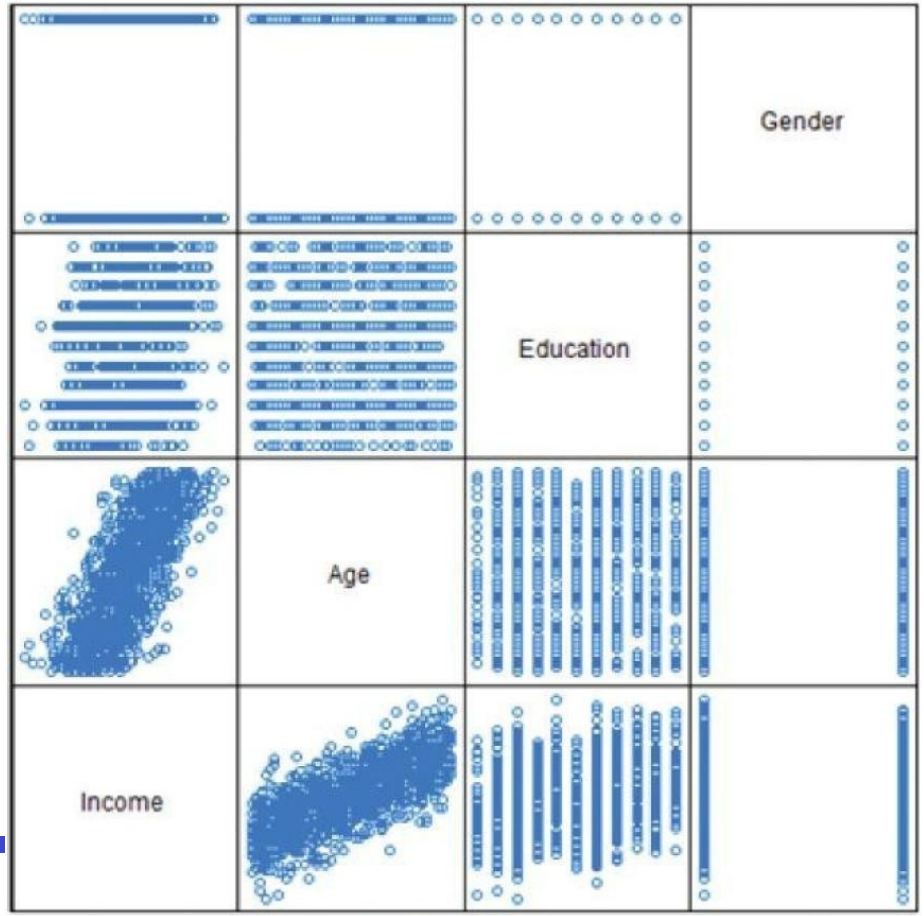

Scatter Plot Matrix

Regresja liniowa – diagnostyka modelu

Założenie o liniowości – przykład sytuacji, gdy założenie nie jest spełnione.

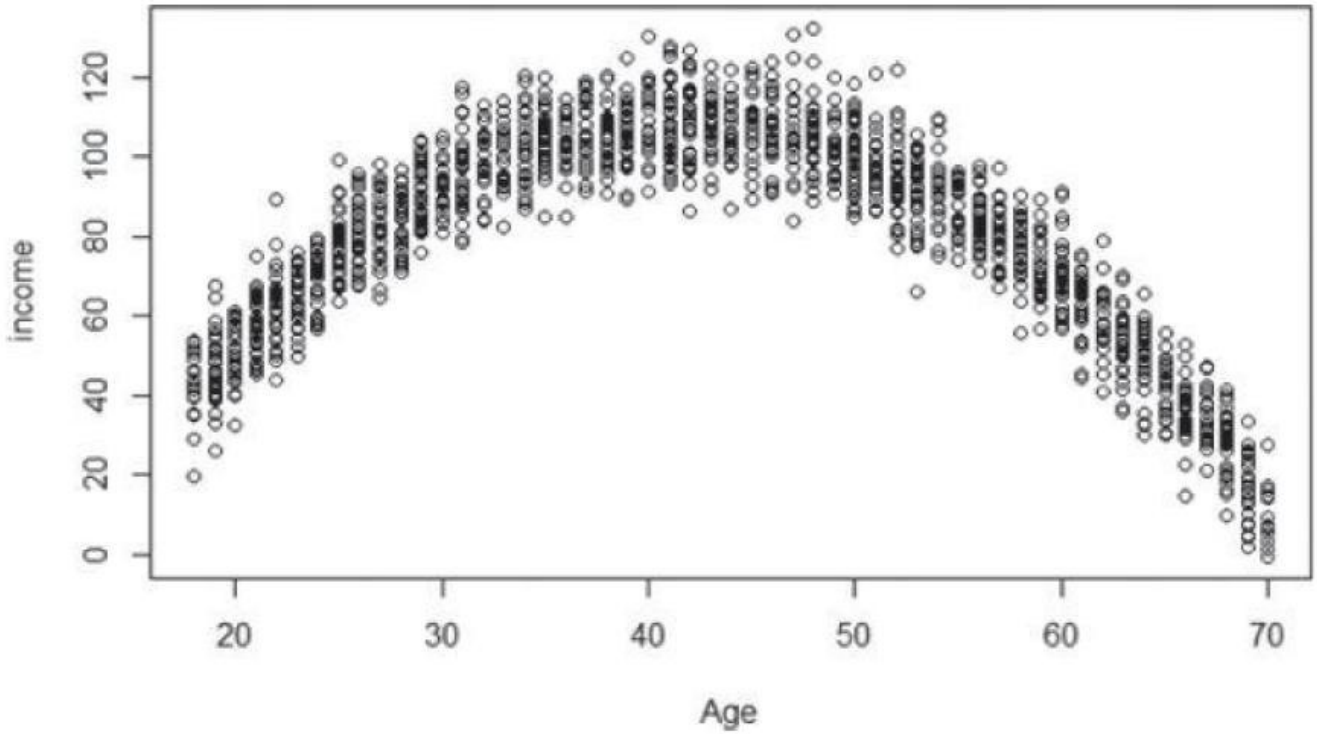

Regresja liniowa – diagnostyka modelu

Ocena reszt (residuals)

Zakłada się, że składniki błędu w modelu regresji liniowej mają rozkład normalny ze średnią równą zero i stałą wariancją. Jeżeli to założenie nie jest spełnione, różne wnioski wyciągnięte z testów hipotez, przedziałów ufności i przedziałów przewidywań są niemiarodajne.

Regresja liniowa – diagnostyka modelu

Ocena reszt (residuals)

Aby sprawdzić stałą wariancję dla wszystkich wartości y wzdłuż linii regresji, można użyć prostego wykresu reszt względem dopasowanych wartości wynikowych. Reszty to różnica pomiędzy obserwowanymi zmiennymi wynikowymi a wartością dopasowaną na podstawie szacunków parametrów OLS.

Regresja liniowa – diagnostyka modelu

Ocena reszt (residuals) – przykład spełnionego założenia

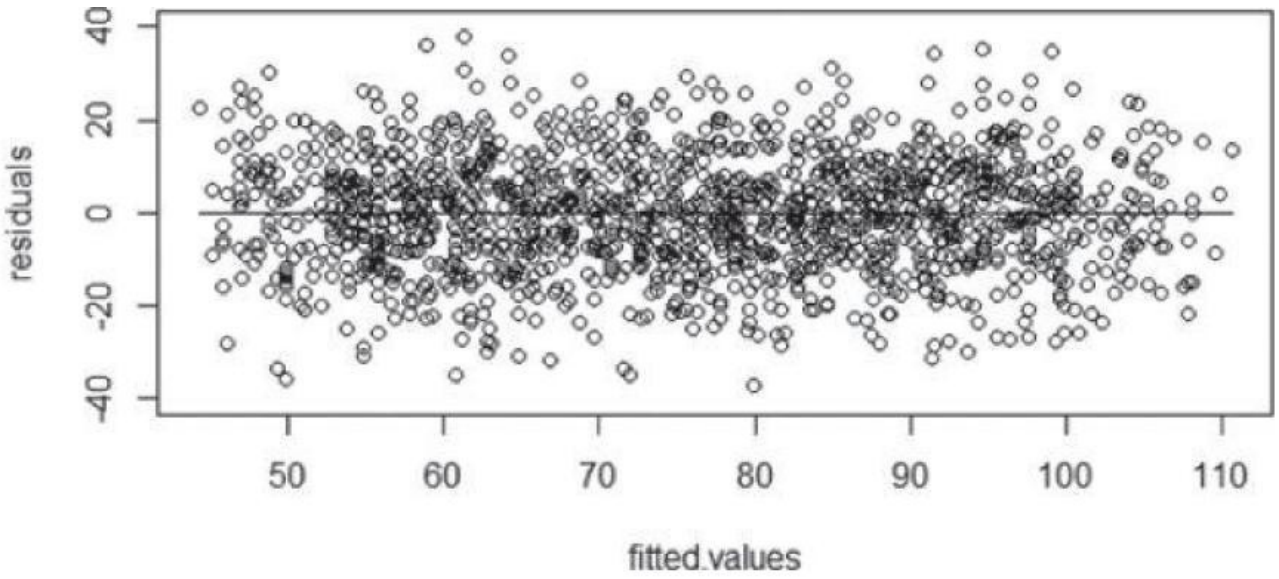

Regresja liniowa – diagnostyka modelu

Ocena reszt (residuals) – nieliniowy trend

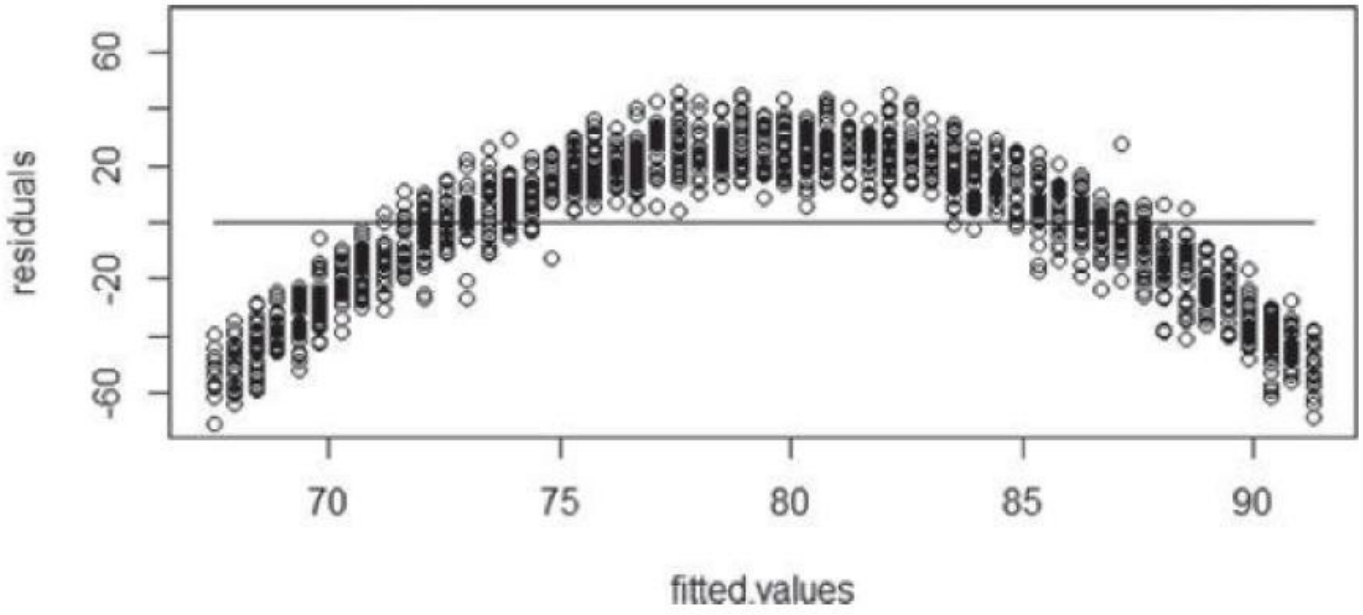

Regresja liniowa – diagnostyka modelu

Ocena reszt (residuals) – centrum poza linią zera

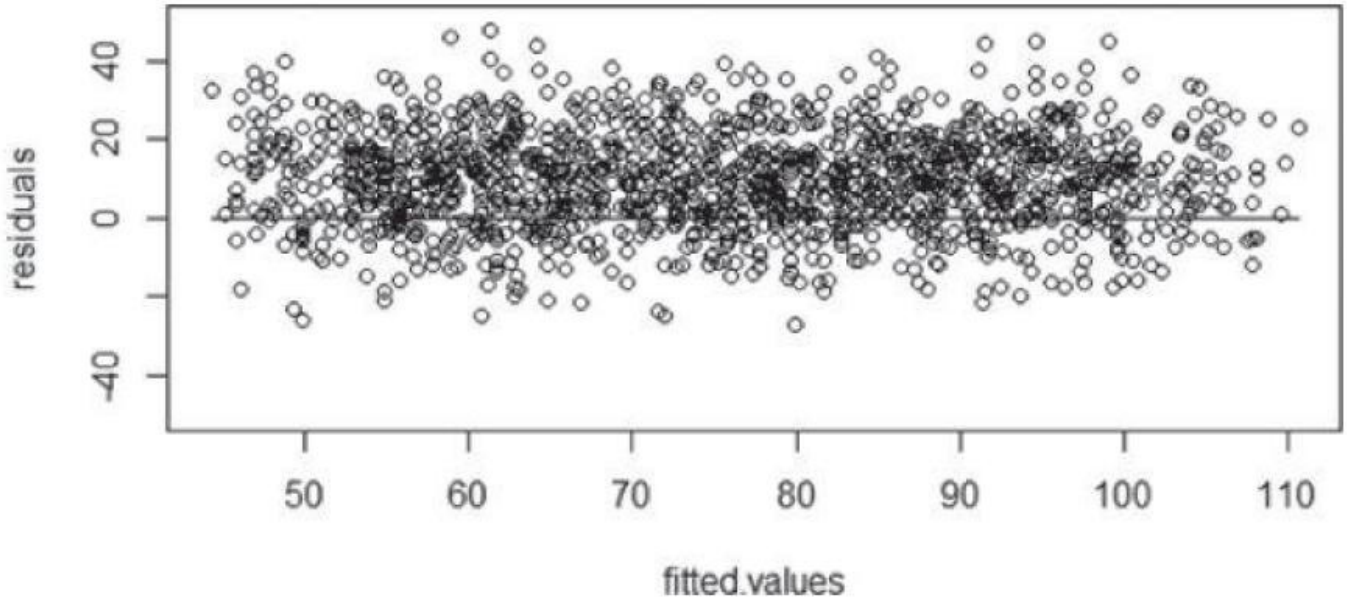

Regresja liniowa – diagnostyka modelu

Ocena reszt (residuals) – wariancja składników błędu nie jest stała

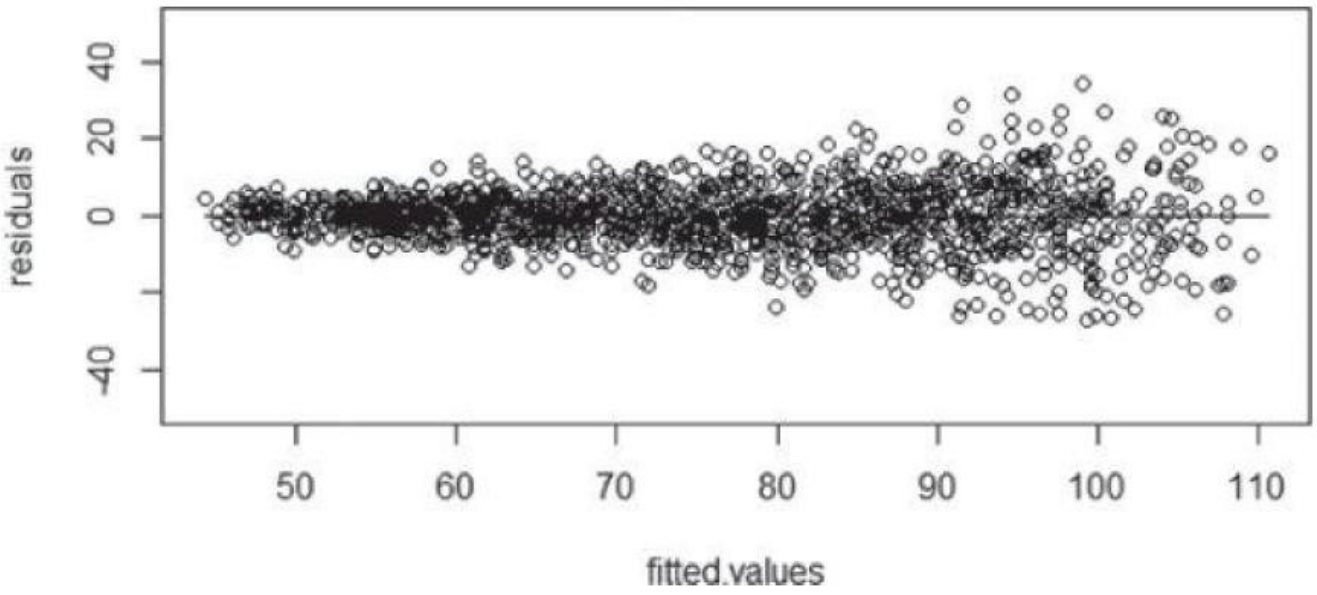

Regresja liniowa – diagnostyka modelu

Ocena założenia normalności

Możemy użyć histogramu rozłożonych reszt lub wykresu Q-Q, który porównuje zaobserwowane dane z kwantylami założonego rozkładu

Regresja liniowa – diagnostyka modelu

Ocena założenia normalności - histogram

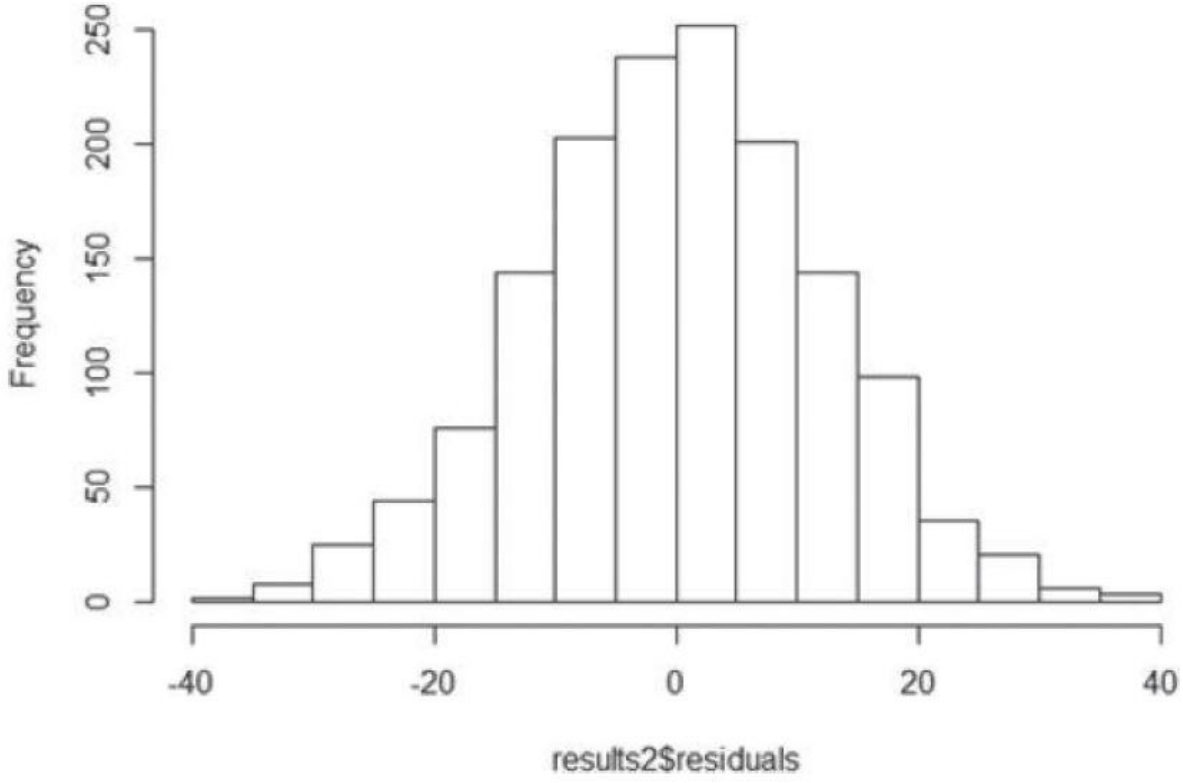

Regresja liniowa – diagnostyka modelu

Ocena założenia normalności – wykres Q-Q

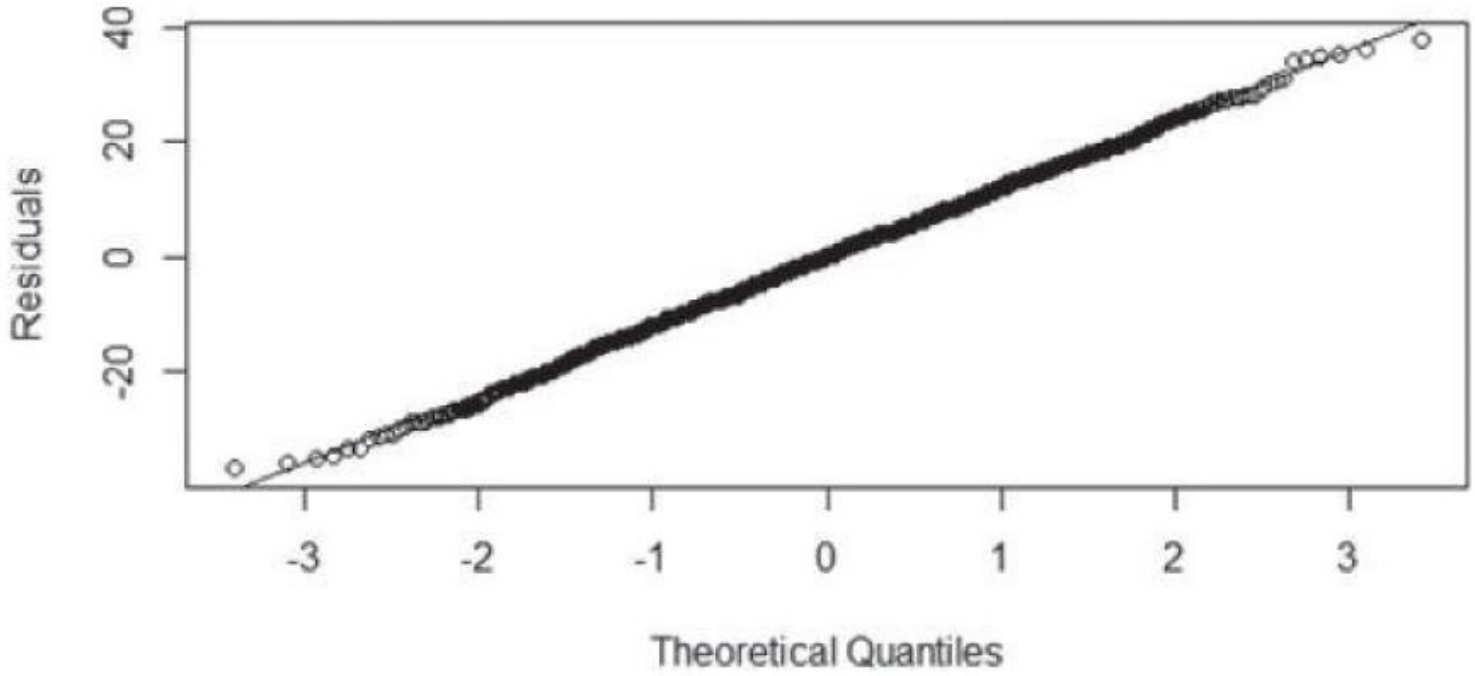

Regresja liniowa – diagnostyka modelu

Ocena założenia normalności – wykres Q-Q dla reszt o rozkładzie normalnym

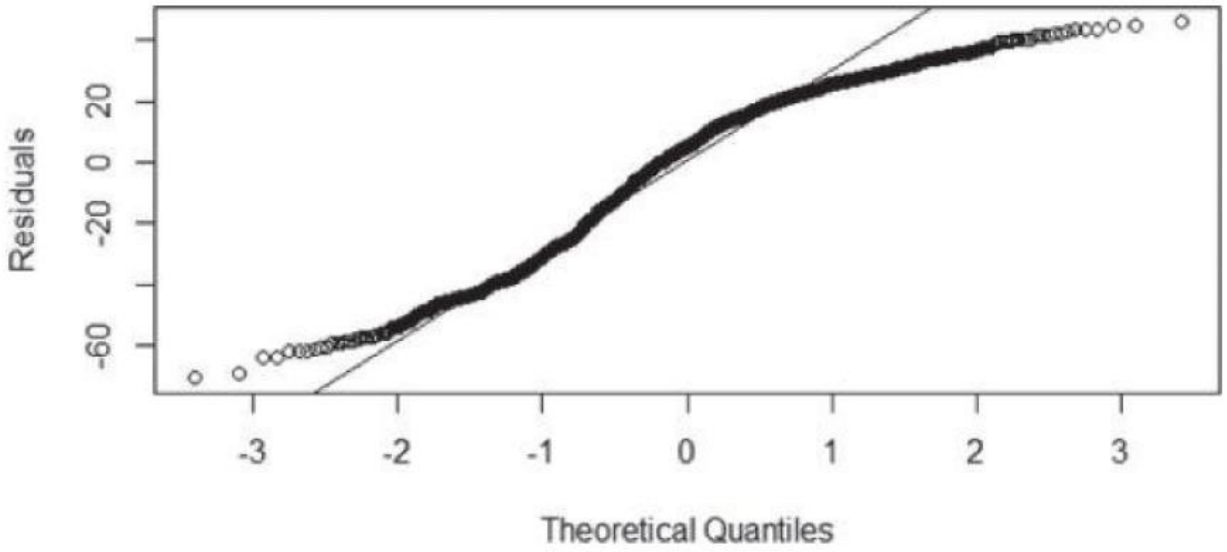

Regresja liniowa – N-krotna weryfikacja krzyżowa

Aby zapobiec nadmiernemu dopasowaniu danego zbioru danych, powszechną praktyką jest losowe dzielenie całego zbioru danych na zbiór uczący i testowy. Po opracowaniu modelu na zestawie szkoleniowym, model jest oceniany w porównaniu ze zbiorem testowym.

Gdy nie ma wystarczającej ilości danych do utworzenia zbiorów uczących i testujących, pomocna może być technika N-krotnej walidacji krzyżowej w celu porównania modeli.

Regresja liniowa – N-krotna weryfikacja krzyżowa

Uśredniony błąd z jednego modelu jest porównywany z uśrednionym błędem z innego modelu.

Technika ta może również pomóc w ustaleniu, czy dodanie większej liczby zmiennych do istniejącego modelu jest korzystne, czy też powoduje nadmierne dopasowanie danych.

Regresja liniowa

Chociaż dopasowany model regresji liniowej jest zgodny z powyższymi kryteriami diagnostycznymi, możliwe jest ulepszenie modelu poprzez uwzględnienie dodatkowych zmiennych wejściowych, które nie zostały jeszcze uwzględnione.

Prognozując dochód, moglibyśmy pierwotnie używać wieku, wykształcenia i płci, ale być może uwzględnienie innych zmiennych, takich jak np. warunki mieszkaniowe, mogłoby jeszcze bardziej ulepszyć model. Ważne jest, aby wziąć pod uwagę wszystkie możliwe zmienne wejściowe na początku procesu analitycznego.

Regresja liniowa

Wykresy resztowe należy zbadać pod kątem wartości odstających, czyli punktów, które znacznie różnią się od większości.

Wartości odstające mogą wynikać z nieprawidłowego gromadzenia danych, błędów przetwarzania danych lub rzeczywistego rzadkiego zdarzenia. Taka obserwacja może mieć negatywny wpływ na dopasowanie modelu regresji.

Regresja liniowa

Należy sprawdzić wielkości i znaki oszacowanych parametrów, aby sprawdzić, czy mają one sens.

Załóżmy na przykład, że uzyskano ujemny współczynnik dla zmiennej Edukacja w przykładzie przewidującym dochód.

Ponieważ naturalne jest założenie, że więcej lat nauki prowadzi do wyższych dochodów, albo odkryliśmy nieoczekiwaną zależność, albo wystąpił jakiś problem z modelem, sposobem gromadzenia danych, lub w grę wchodzi inny czynnik. We wszystkich przypadkach uzasadnione jest dalsze sprawdzenie tego trendu.

Regresja logistyczna

W modelowaniu regresji liniowej zmienna wynikowa jest zmienną ciągłą. Jeżeli zmienna wynikowa ma charakter kategoryczny, można zastosować regresję logistyczną do przewidzenia prawdopodobieństwa wyniku na podstawie zmiennych wejściowych.

Regresję logistyczną można zastosować do zmiennej wynikowej, która reprezentuje wiele wartości, natomiast przeważnie będzie się to odbywało w kontekście dwóch wartości dla każdej klasy, takich jak prawda/fałsz, wynik pozytywny/negatywny lub tak/nie.

Regresja logistyczna

Przykładowo, można zbudować model regresji logistycznej w celu ustalenia, czy dana osoba kupi nowy samochód w ciągu najbliższych 12 miesięcy.

Zbiór uczący może zawierać zmienne wejściowe dotyczące wieku, dochodów i płci danej osoby, a także wieku samochodu. Zbiór uczący obejmowałby również zmienną wynikową dotyczącą tego, czy dana osoba kupiła nowy samochód w okresie 12 miesięcy.

Model regresji logistycznej określa prawdopodobieństwo, że dana osoba dokona zakupu w ciągu najbliższych 12 miesięcy.

Regresja logistyczna - wykorzystanie

Medycyna: model określający prawdopodobieństwo pomyślnej reakcji pacjenta na określone leczenie lub procedurę medyczną. Zmienne wejściowe mogą obejmować wiek, wagę, ciśnienie krwi i poziom cholesterolu, etc.

Finanse: Korzystając z historii kredytowej osoby ubiegającej się o pożyczkę i szczegółów pożyczki, można określać prawdopodobieństwo, że wnioskodawca nie spłaci pożyczki. Na podstawie przewidywań pożyczka może zostać zatwierdzona lub odrzucona, a także można zmodyfikować jej warunki.

Regresja logistyczna - wykorzystanie

Marketing: prawdopodobieństwo zmiany operatora przez klienta sieci bezprzewodowej na podstawie wieku, liczby członków rodziny objętych planem, miesięcy pozostałych w istniejącej umowie i kontaktów w sieciach społecznościowych. Mając taką wiedzę, można skierować odpowiednie oferty do klientów aby zapobiec ich odejściu.

Inżynieria: w oparciu o warunki pracy i różne pomiary diagnostyczne określamy prawdopodobieństwo nieprawidłowego działania lub awarii części mechanicznej. Na podstawie tego oszacowania można planować działania w zakresie konserwacji zapobiegawczej.

Regresja logistyczna - wykorzystanie

Regresja logistyczna opiera się na funkcji logistycznej:

$$f(y) = \frac{e^y}{1+e^y} \; for -\infty < y < \infty$$

Gdzie dla $y \to \infty$, f(y) zbiega do 1, a gdy $y \to -\infty$, wartość zbiega do 0.

Ogólnie rzecz biorąc, wartość funkcji logistycznej zmienia się od 0 do 1 wraz ze wzrostem y.

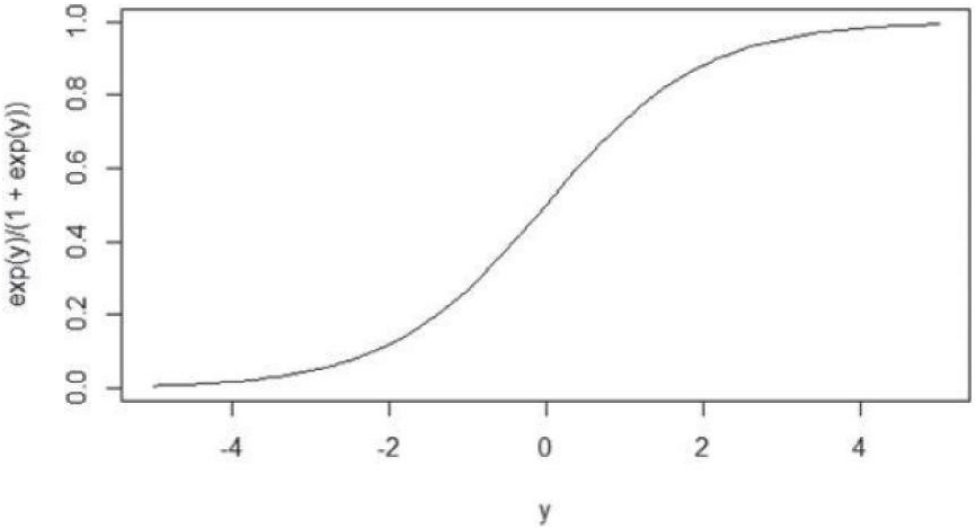

Regresja logistyczna - wykorzystanie

Ponieważ zakres funkcji logistycznej wynosi (0, 1), jest to odpowiednia funkcja do modelowania prawdopodobieństwa wystąpienia określonego wyniku.

Wraz ze wzrostem wartości funkcji wzrasta prawdopodobieństwo wystąpienia wyniku.

W dowolnym proponowanym modelu, aby przewidzieć prawdopodobieństwo wyniku, y musi być funkcją zmiennych wejściowych. W regresji logistycznej y wyraża się jako funkcję liniową zmiennych wejściowych.

Regresja logistyczna - diagnostyka

Odchylenie i pseudo-R^2

W regresji logistycznej odchylenie definiuje się jako -2*logL, gdzie L jest maksymalną wartością funkcji wiarygodności użytej do uzyskania estymatorów parametrów.

Odchylenie zerowe to wartość, w przypadku której funkcja wiarygodności opiera się wyłącznie na wartości wyrazu wolnego (y=β_0).

Odchylenie resztkowe to wartość, w przypadku której funkcja wiarygodności opiera się na parametrach określonego modelu logistycznego.

Regresja logistyczna - diagnostyka

Metrykę analogiczną do R^2 w regresji liniowej można obliczyć za pomocą następującego równania:

$$pseudo - R^2 = 1 - \frac{residual\ dev.}{null\ dev.} = \frac{null\ dev. - res.\ dev.}{null\ dev.}$$

Pseudo-R^2 jest miarą tego, jak dobrze dopasowany model wyjaśnia dane w porównaniu z modelem domyślnym bez zmiennych predykcyjnych, a jedynie wyrazem wolnym. Jego wartość bliska 1 wskazuje na dobre dopasowanie w stosunku do modelu zerowego.

Regresja logistyczna - diagnostyka

Krzywa charakterystyki działania odbiornika (ROC).

Przydatność tego wykresu polega na tym, że preferowanym wynikiem klasyfikatora jest niski FPR i wysoki TPR. Tak więc, podczas poruszania się od lewej do prawej na osi FPR, dobry model/klasyfikator charakteryzuje się tym, że TPR szybko zbliża się do wartości bliskich 1, z jedynie niewielką zmianą FPR. Im bliżej krzywa ROC przebiega wzdłuż osi pionowej i zbliża się do lewego górnego rogu wykresu, w pobliżu punktu (0,1), tym lepiej działa model/klasyfikator.

Regresja logistyczna - diagnostyka

Krzywa charakterystyki działania odbiornika (ROC).

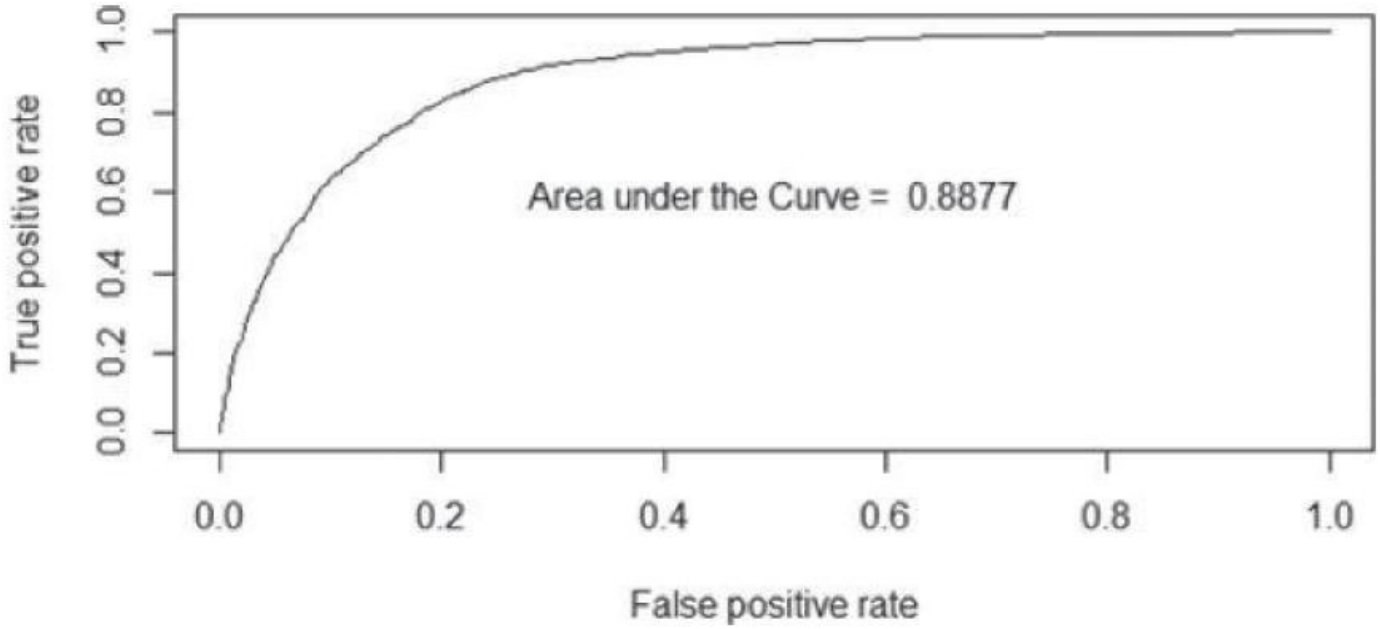

Regresja logistyczna - diagnostyka

Histogram prawdopodobieństw

Przydatna może być wizualizacja zaobserwowanych odpowiedzi w porównaniu z oszacowanymi prawdopodobieństwami określonymi przez regresję logistyczną. Histogram pomaga zwizualizować liczbę elementów, poprawnie lub błędnie sklasyfikowanych.

Uwagi ogólne

Regresja liniowa jest odpowiednia, gdy zmienne wejściowe są ciągłe lub dyskretne, włączając dane kategoryczne, ale zmienna wynikowa jest ciągła.

Jeśli zmienna wynikowa jest kategoryczna, lepszym wyborem jest regresja logistyczna.

Uwagi ogólne

Obydwa modele zakładają liniową funkcję addytywną zmiennych wejściowych. Jeżeli takie założenie nie jest prawdziwe, obie techniki regresji sprawdzają się słabo.

W przypadku regresji liniowej zakładamy, że składniki błędu mają rozkład normalny i stałą wariancję. Jeżeli wydaje się, że założenia modelu nie są spełnione, do danych należy zastosować odpowiednie przekształcenia.

Uwagi ogólne

Chociaż zbiór zmiennych wejściowych może być dobrym predyktorem zmiennej wynikowej, nie powinniśmy zakładać, że zmienne wejściowe bezpośrednio powodują wynik.

Uwagi ogólne

Można na przykład stwierdzić, że u osób regularnie odwiedzających dentystę ryzyko zawału serca jest zmniejszone. Jednak samo wysłanie kogoś do dentysty prawie na pewno nie ma wpływu na ryzyko zawału serca u tej osoby.

Możliwe jest, że regularne wizyty u dentysty mogą wskazywać na ogólny stan zdrowia i wybory żywieniowe, co może mieć bardziej bezpośredni wpływ na zdrowie. Ten przykład ilustruje powszechnie znane wyrażenie: „Korelacja nie implikuje związku przyczynowego”.

Uwagi ogólne

Należy zachować ostrożność podczas stosowania już dopasowanego modelu do danych, które wykraczają poza zbiór wykorzystany do uczenia modelu. Zależność liniowa w modelu regresji może nie mieć zastosowania dla wartości poza zbiorem z danych szkoleniowych.

Na przykład, jeśli dochód był zmienną wejściową, a jego wartość wahała się od 35 000 do 90 000 dolarów, zastosowanie modelu do dochodów odbiegających od tych wartości może skutkować niedokładnymi przewidywaniami.

Uwagi ogólne

Jeśli kilka zmiennych wejściowych jest ze sobą silnie skorelowanych, warunek ten nazywa się współliniowością.

Współliniowość może często prowadzić do niepoprawnych oszacowań (zbyt duże wartości przypisane zmiennym, zły znak, etc.). Jeśli to możliwe, większość skorelowanych zmiennych powinna zostać usunięta z modelu lub zastąpiona nową zmienną będącą ich funkcją.

Inne modele regresji

W przypadku współliniowości sensowne może być nałożenie pewnych ograniczeń na wielkości szacowanych współczynników.

Jedną z technik, którą można zastosować, jest **regresja grzbietowa (Ridge)**, która nakłada karę na podstawie wielkości współczynników. Dopasowując model regresji liniowej, celem jest znalezienie wartości współczynników, które minimalizują sumę kwadratów reszt. W regresji grzbietowej składnik kary proporcjonalny do sumy kwadratów współczynników jest dodawany do sumy kwadratów reszt.

Inne modele regresji

Regresja Lasso jest pokrewną techniką modelowania, w której kara jest proporcjonalna do sumy wartości bezwzględnych współczynników.

Za pomocą regresji logistycznej badamy jedynie binarne zmienne wynikowe. Jeżeli zmienna wynikowa może przyjmować więcej niż dwa stany, można zastosować **wielomianową regresję logistyczną.**

Inne modele regresji

Chociaż analiza regresji jest stosunkowo prosta do przeprowadzenia przy użyciu wielu istniejących pakietów oprogramowania, należy zachować szczególną ostrożność podczas wykonywania i interpretacji otrzymanych w ten sposób wyników.

Inne modele regresji

Podczas analizy z wykorzystaniem regresji analityk danych musi wykonać następujące czynności:

- Określić najlepsze zmienne wejściowe i ich związek ze zmienną wynikową.
- Zrozumieć podstawowe założenia i ich wpływ na wyniki modelowania.
- W razie potrzeby przekształć zmienne, aby uzyskać zgodność z założeniami modelu.
- Zdecydować, czy najlepszym wyborem będzie zbudowanie jednego kompleksowego modelu, czy też wielu modeli.

KLASYFIKACJA

Klasyfikacja

Oprócz metod analitycznych, takich jak grupowanie, reguły asocjacyjne, czy techniki modelowania, takie jak regresja, klaryfikacja jest kolejnym z podstawowych problemów przy analizie i eksploracji danych.

Podczas procesu, klasyfikatorowi zostaje przedstawiony zestaw przykładów, które są już opisane. Na podstawie tych przykładów model uczy się przypisywać nowe przykłady.

Klasyfikacja

Regresja logistyczna jest jedną z popularnych metod klasyfikacji. Zestaw etykiet dla klasyfikatorów jest z góry określony, w przeciwieństwie do grupowania, które odkrywa strukturę istniejącą w danych i pozwala analitykowi tworzyć i przypisywać etykiety do klastrów.

Klasyfikacja

Większość metod klasyfikacji jest nadzorowana, ponieważ wymagają danych z oznaczonymi przykładami.

Przykładowo, istniejące dane marketingowe, sprzedażowe i demograficzne klientów można wykorzystać do opracowania klasyfikatora w celu przypisania potencjalnym przyszłym klientom etykiety „zakup” lub „brak zakupu”.

Klasyfikacja jest często wykorzystywana w zadaniach predykcyjnych.

Drzewa decyzyjne

Drzewo decyzyjne (zwane także drzewem predykcyjnym) wykorzystuje strukturę drzewa do określenia sekwencji decyzji prowadzących do konkretnej klasyfikacji przykładu.

Mając dany zestaw wejściowy, celem jest przewidzenie odpowiedzi lub zmiennej wyjściowej. Każdy element zbioru wejściowego nazywany jest zmienną wejściową. Przewidywanie można osiągnąć poprzez skonstruowanie drzewa decyzyjnego z węzłami testowymi i gałęziami.

Drzewa decyzyjne

W każdym węźle testowym podejmowana jest decyzja o wybraniu konkretnej gałęzi i przejściu w dół drzewa. Każdy punkt testowy w drzewie decyzyjnym obejmuje sprawdzenie określonej zmiennej wejściowej (lub atrybutu), a każda gałąź reprezentuje podejmowaną decyzję.

Ze względu na swoją elastyczność i łatwą wizualizację drzewa decyzyjne są powszechnie stosowane w aplikacjach do eksploracji danych w celu klasyfikacji.

Drzewa decyzyjne

Wartości wejściowe drzewa decyzyjnego mogą być kategoryczne lub ciągłe. Drzewo decyzyjne wykorzystuje strukturę punktów testowych (zwanych węzłami) i gałęzi, które reprezentują podejmowaną decyzję. Węzeł bez dalszych rozgałęzień nazywany jest liściem.

Węzły-liście zwracają etykiety klas, a w niektórych implementacjach, zwracają wyniki prawdopodobieństwa.

Drzewo decyzyjne można przekształcić w zbiór reguł decyzyjnych.

Drzewa decyzyjne

Drzewa decyzyjne mają dwie odmiany: drzewa klasyfikacyjne i drzewa regresji.

Drzewa klasyfikacyjne zwykle odnoszą się do zmiennych wyjściowych kategorycznych – często binarnych, takich jak „tak” lub „nie”, „kupuję” lub „nie kupuję”.

Z drugiej strony **drzewa regresji** można zastosować do zmiennych wyjściowych, które mają charakter liczbowy lub ciągły, takich jak przewidywana cena towaru konsumpcyjnego lub prawdopodobieństwo zakupu subskrypcji.

Drzewa decyzyjne

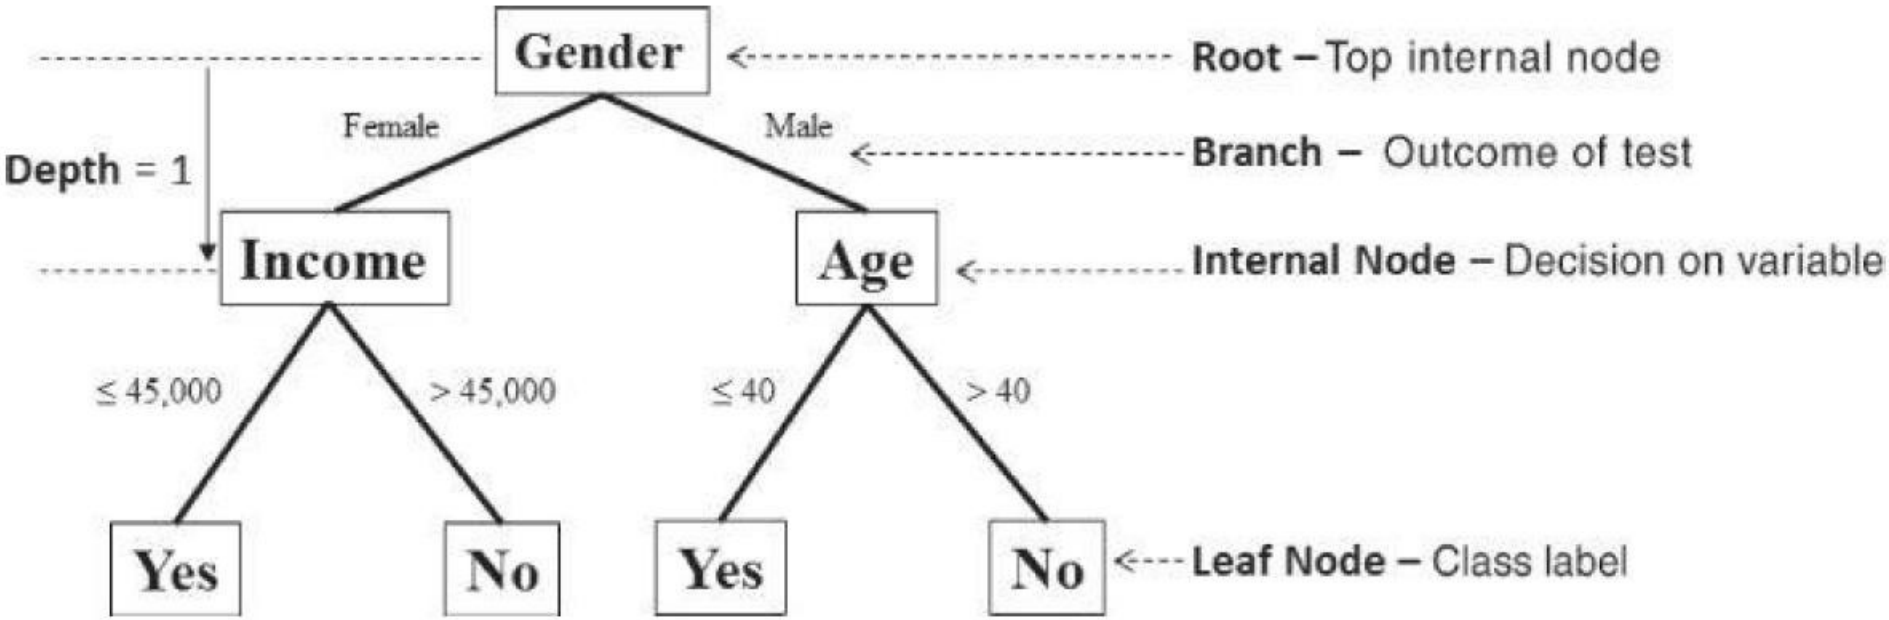

Drzewa decyzyjne

Węzły wewnętrzne to punkty decyzyjne lub testowe.

Najwyższy węzeł wewnętrzny nazywany jest **korzeniem**.

Drzewo decyzyjne pokazane na poprzednim slajdzie jest **drzewem binarnym**, w którym każdy węzeł wewnętrzny ma nie więcej niż dwie gałęzie.

Głębokość węzła to minimalna liczba kroków wymaganych do osiągnięcia węzła zaczynając od korzenia.

Drzewa decyzyjne

Liście znajdują się na końcach gałęzi drzewa. Reprezentują etykiety klasowe – wynik wszystkich wcześniejszych decyzji. Ścieżka od korzenia do węzła liścia zawiera szereg decyzji podjętych w różnych węzłach wewnętrznych.

Drzewa decyzyjne

Ograniczając liczbę podziałów, można utworzyć krótkie drzewo. Krótkie drzewa są często używane jako elementy w metodach zespołowych.

Metody zespołowe wykorzystują wiele modeli predykcyjnych, decyzja jest podejmowana na podstawie wyników głosowania grupy klasyfikatorów. Niektóre popularne metody zespołowe: losowy las, bagging, boosting.

Najprostsze krótkie drzewo nazywa się **pniem** i jest drzewem decyzyjnym, którego korzeń jest bezpośrednio połączony z liśćmi.

Drzewa decyzyjne

Tworząc drzewo decyzyjne, przy każdym podziale algorytm wybiera spośród pozostałych atrybutów taki, który wnosi jak najwięcej informacji. Stopień ten określa się za pomocą takich parametrów, jak:

- **Entropia**
- **Zysk informacyjny**

Drzewa decyzyjne

Często konieczne jest zmierzenie istotności podziału w drzewie decyzyjnym, szczególnie gdy zysk informacyjny jest niewielki.

Po każdym podziale algorytm sprawdza wszystkie rekordy w liściu i na ich podstawie ponownie obliczany jest zysk informacyjny dotyczący każdego potencjalnego atrybutu. Następny podział wybierze atrybut z największym przyrostem informacji.

Drzewa decyzyjne

Przykładowe algorytmy, wykorzystywane do tworzenia drzew decyzyjnych:

- ID3 (Iterative Dichotomiser 3)
- C4.5
- CART (Classification And Regression Trees)

Większość dostępnych bibliotek do AI/ML będzie posiadała implementacje powyższych metod.

Drzewa decyzyjne - ewaluacja

Drzewa decyzyjne wykorzystują algorytmy zachłanne, w tym sensie, że zawsze wybierają opcję, która wydaje się najlepsza w danym momencie. Na każdym etapie algorytm wybiera atrybut, który ma zostać użyty do podziału pozostałych rekordów.

Rezultat może nie być najlepszy możliwy, ale będzie najlepszy w ramach danego etapu. Ta cecha zwiększa efektywność drzew decyzyjnych.

Wadą jest to, że nieoptymalne podziały propagują się na resztę drzewa i wpływają na jego efektywność.

Drzewa decyzyjne - ewaluacja

Aby rozwiązać ten problem, można zastosować technikę zespołową (taką jak las losowy) w celu losowego podziału lub randomizacji danych i uzyskania struktury z wieloma drzewami. Drzewa te następnie głosują i wybierana jest klasa z największą liczbą głosów.

Drzewa decyzyjne - ewaluacja

Istnieje kilka sposobów oceny drzewa decyzyjnego:

- Sprawdzenie, czy podziały maja sens
- Weryfikacja głębokości drzewa
- Określenie maksymalnej ilości poziomów drzewa
- Przycinanie zbyt głębokiego drzewa
- Tworzenie wielu wersji drzewa

Drzewa decyzyjne - ewaluacja

Drzewa decyzyjne po wytrenowaniu są niedrogie obliczeniowo i umożliwiają łatwą klasyfikację danych. Wyniki są interpretowalne jako sekwencja prostych testów.

Wiele algorytmów drzew decyzyjnych jest w stanie pokazać znaczenie zmiennych wejściowych.

Drzewa decyzyjne - ewaluacja

Drzewa decyzyjne są w stanie obsłużyć zarówno atrybuty liczbowe, jak i kategorialne, są odporne na nadmiarowe lub skorelowane zmienne i mogą obsługiwać atrybuty kategoryczne z wieloma różnymi wartościami.

Drzewa decyzyjne mogą również obsługiwać zmienne, które mają nieliniowy wpływ na wynik. W naturalny sposób radzą sobie z interakcjami pomiędzy zmiennymi jako że każdy węzeł w drzewie zależy od poprzednich.

Drzewa decyzyjne - ewaluacja

Drzewa decyzyjne nie są dobrym wyborem, jeśli zbiór danych zawiera wiele nieistotnych zmiennych.

Są one odporne na zbędne zmienne (redundant) i zmienne skorelowane. Jeśli zbiór danych zawiera nadmiarowe zmienne, powstałe drzewo decyzyjne ignoruje wszystkie z wyjątkiem jednej z tych zmiennych, ponieważ algorytm nie wykrywa przyrostu informacji z uwzględnienia większej liczby zbędnych zmiennych.

Drzewa decyzyjne - ewaluacja

Jeśli zbiór danych zawiera nieistotne zmienne i jeśli te zmienne zostaną wybrane jako podziały w drzewie, może stać się ono zbyt duże, co prawdopodobnie spowoduje nadmierne dopasowanie.

Aby rozwiązać ten problem, można wprowadzić selekcję cech na etapie wstępnego przetwarzania danych, aby wyeliminować nieistotne zmienne.

Drzewa decyzyjne - ewaluacja

Chociaż drzewa decyzyjne są w stanie obsłużyć skorelowane zmienne, nie radzą sobie dobrze, gdy większość zmiennych w zbiorze uczącym jest skorelowana, gdyż zwiększa to ryzyko nadmiernego dopasowania.

W celu uniknięcia tego, można połączyć decyzje kilku losowych płytkich drzew decyzyjnych lub zastosować metody zespołowe w celu połączenia kilku słabych klasyfikatorów.

Metody te poprawiają moc predykcyjną w porównaniu z pojedynczym drzewem decyzyjnym.

Drzewa decyzyjne - ewaluacja

W przypadku binarnych drzew, najlepiej jeśli zbiór danych szkoleniowych składa się z rekordów o równym prawdopodobieństwie każdego wyniku. Innymi słowy, korzeń drzewa ma 50% szans na którąkolwiek klasyfikację.

Odbywa się to poprzez losowe wybieranie równej liczby rekordów szkoleniowych z każdej możliwej klasyfikacji.

Naiwny Bayes

Naiwny Bayes to probabilistyczna metoda klasyfikacji oparta na twierdzeniu Bayesa (lub prawie Bayesa) z kilkoma poprawkami.

Naiwny klasyfikator Bayesa zakłada, że obecność lub brak określonej cechy klasy nie jest powiązany z obecnością lub brakiem innych cech.

Dane wyjściowe zazwyczaj zawierają etykietę klasy i odpowiadający jej wynik prawdopodobieństwa. Wynik prawdopodobieństwa nie jest prawdziwym prawdopodobieństwem etykiety klasy, ale jest do niego proporcjonalny.

Naiwny Bayes

Ponieważ naiwne klasyfikatory Bayesa są łatwe w implementacji i można je efektywnie wykonywać nawet bez wcześniejszej znajomości danych, należą one do najpopularniejszych algorytmów klasyfikacji dokumentów tekstowych.

Filtrowanie spamu to klasyczny przypadek użycia tej metody do klasyfikacji tekstu. Filtrowanie spamu metodą bayesowską stało się popularnym mechanizmem pozwalającym odróżnić spam od prawidłowych wiadomości e-mail.

Naiwny Bayes

W przeciwieństwie do regresji logistycznej naiwne klasyfikatory Bayesa radzą sobie z brakującymi danymi. Naiwny Bayes jest również odporny na nieistotne zmienne.

Model jest prosty w implementacji nawet bez użycia bibliotek. Predykcja opiera się na zliczaniu wystąpień zdarzeń, dzięki czemu działanie klasyfikatora jest efektywne. Naiwny Bayes jest wydajny i potrafi efektywnie obsługiwać dane wielowymiarowe.

Naiwny Bayes

Naiwny klasyfikator Bayesa w wielu przypadkach jest konkurencyjny w stosunku do innych algorytmów uczących, w tym drzew decyzyjnych i sieci neuronowych. W niektórych przypadkach naiwny Bayes przewyższa nawet inne metody. Dodatkowo, radzi sobie z wielopoziomowymi danymi kategorycznymi.

Diagnostyka klasyfikatorów

Opracowano kilka narzędzi służących do oceny wydajności klasyfikatora. Narzędzia takie służą ogólnej ocenie klasyfikatorów.

Przykładowe metody:

- Macierz konfuzji (confusion matrix)
- Dokładność (accuracy)
- TPR (True-Positive Rate)
- FPR (False-Positive Rate)
- FNR (False-Negative Rate)
- Precyzja
- Recall
- Krzywa ROC
- AUC (Area under the ROC curve)

Dodatkowe metody klasyfikacji

Bagging (bootstrap aggregating) wykorzystuje technikę bootstrap, która wielokrotnie pobiera próbki ze zbioru danych zgodnie z jednolitym rozkładem prawdopodobieństwa.

Ponieważ próbkowanie odbywa się z powtórzeniami, niektóre próbki mogą pojawić się kilka razy w zbiorze uczącym lub testowym, podczas gdy inne mogą być nieobecne. Model lub klasyfikator bazowy jest szkolony oddzielnie na każdej próbie, a próbka testowa jest przydzielana do klasy, która otrzymała największą liczbę głosów.

Dodatkowe metody klasyfikacji

Boosting (Wzmocnienie, AdaBoost) wykorzystuje głosowanie w klasyfikacji w celu łączenia wyników poszczególnych modeli.

Wzmocnienie to procedura iteracyjna, podczas której na nowy model wpływa wydajność modeli zbudowanych wcześniej. Co więcej, podczas wzmacniania przypisuje się wagę do każdej próbki treningowej, która odzwierciedla jej znaczenie, a waga może zmieniać się adaptacyjnie na koniec każdej rundy wzmacniania.

Dodatkowe metody klasyfikacji

Las losowy to klasa metod zespołowych wykorzystujących drzewa decyzyjne. Jest to kombinacja predyktorów, w której każde drzewo zależy od wartości wektora losowego próbkowanego niezależnie i z tym samym rozkładem dla wszystkich drzew.

Specjalny przypadek losowego lasu wykorzystuje bagging, gdzie próbki są wybierane losowo z oryginalnego zbioru treningowego.

Dodatkowe metody klasyfikacji

SVM (Support Vector Machine) to kolejna powszechna metoda klasyfikacji, która łączy modele liniowe z technikami uczenia się opartymi na instancjach.

Maszyny wektorów nośnych wybierają z każdej klasy niewielką liczbę krytycznych instancji brzegowych zwanych wektorami nośnymi i budują liniową funkcję decyzyjną, która oddziela je tak szeroko, jak to możliwe.

SVM może efektywnie przeprowadzać klasyfikacje liniowe. Rozwiązanie może też być skonfigurowane do wykonywania klasyfikacji nieliniowych.

Przykład doboru rozwiązań

Concerns	Recommended Method(s)
Output of the classification should include class probabilities in addition to the class labels.	Logistic regression, decision tree
Analysts want to gain an insight into how the variables affect the model.	Logistic regression, decision tree
The problem is high dimensional.	Naïve Bayes
Some of the input variables might be correlated.	Logistic regression, decision tree
Some of the input variables might be irrelevant.	Decision tree, naïve Bayes
The data contains categorical variables with a large number of levels.	Decision tree, naïve Bayes
The data contains mixed variable types.	Logistic regression, decision tree
There is nonlinear data or discontinuities in the input variables that would affect the output.	Decision tree

ANALIZA SZEREGÓW CZASOWYCH

Analiza szeregów czasowych

Analiza szeregów czasowych ma na celu modelowanie podstawowej struktury obserwacji przeprowadzonych w czasie. Szereg czasowy to uporządkowana sekwencja wartości równomiernie rozmieszczonych w czasie.

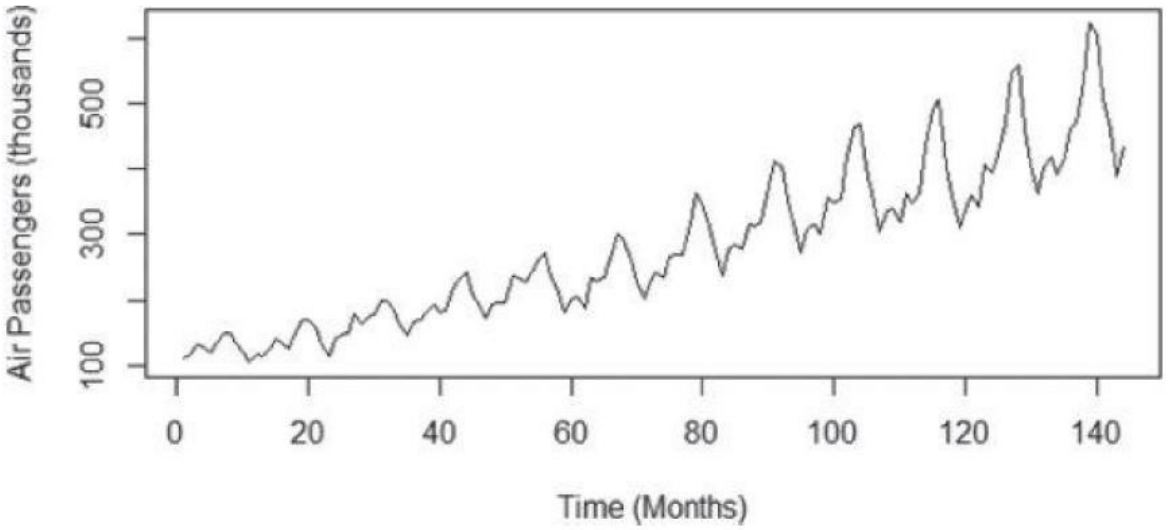

Analiza szeregów czasowych

Analizy, które rozważamy, ograniczają się do równomiernie rozmieszczonych szeregów czasowych jednej zmiennej.

Główne cele analizy szeregów czasowych:

- Identyfikacja i modelowanie struktury szeregów czasowych.
- Prognozowanie przyszłych wartości w szeregach czasowych.

Analiza szeregów czasowych

Analiza szeregów czasowych może znaleźć zastosowanie w wielu dziedzinach:

- Przewidywanie sprzedaży dla różnych produktów
- Planowanie zakupu części zamiennych
- Handel akcjami

Analiza szeregów czasowych

Szereg czasowy może składać się z następujących elementów:

- Trend
- Sezonowość
- Cykliczność
- Losowość

Analiza szeregów czasowych

- **Trend** odnosi się do długoterminowego ruchu w szeregu czasowym
- **Sezonowość** opisuje stałą, okresową fluktuację obserwacji w czasie.
- **Cykliczność** również odnosi się do wahań okresowych, ale nie tak stałych, jak w przypadku składnika sezonowego.

Po uwzględnieniu trzech powyższych czynników, pozostaje **składnik losowy**. Szum jest częścią losowego składnika, często istnieje pewna podstawowa struktura, którą należy zamodelować, aby prognozować przyszłe wartości danego szeregu czasowego.

Metodologia Box-Jenkins

Metodologia opracowana przez George'a Boxa i Gwilyma Jenkinsa, wykorzystywana do analizy szeregów czasowych obejmuje trzy główne etapy:

1. Sprawdź dane i wybierz model.
    1. Zidentyfikuj i uwzględnij wszelkie trendy lub sezonowość w szeregach czasowych.
    2. Sprawdź pozostałe szeregi czasowe i wybierz odpowiedni model.
2. Oszacuj parametry modelu.
3. Oceń model i jeśli to konieczne, wróć do kroku 1.

Model ARMA

Model ARMA (autoregresywna średnia ruchoma) jest popularnym modelem statystycznym stosowanym w analizie szeregów czasowych.

Łączy model autoregresyjny (AR) i model średniej ruchomej (moving average, MA).

Model ARMA

Założenia i wymagania

Stacjonarność: Model ARMA zakłada, że szereg czasowy jest stacjonarny, co oznacza, że właściwości statystyczne, takie jak średnia i wariancja, są stałe w czasie. Dane niestacjonarne można często przekształcić w dane stacjonarne za pomocą różnicowania lub innych transformacji.

Błędy białego szumu: Zakłada się, że składniki błędów są białym szumem, co oznacza, że są nieskorelowane i mają stałą średnią i wariancję.

Model ARMA

Model ARMA jest szeroko stosowany w ekonomii, finansach, inżynierii i innych dziedzinach do:

- Prognozowanie przyszłych wartości szeregu czasowego
- Zrozumienie podstawowych wzorców i struktur danych
- Filtrowania lub wygładzania zaszumionych danych

Model ARIMA

ARIMA (Auto-Regressive Integrated Moving Average) to popularny model prognozowania szeregów czasowych. Jest szeroko stosowany w różnych dziedzinach do analizowania i przewidywania przyszłych wartości na podstawie przeszłych obserwacji w zestawie danych szeregów czasowych.

Model ARIMA łączy w sobie trzy kluczowe elementy: autoregresję (AR), różnicowanie (I) i średnią ruchomą (MA).

Model ARIMA

Zastosowania:

- Prognozowanie finansowe: prognozowanie cen akcji, kursów walut i innych wskaźników finansowych
- Prognozowanie popytu: przewidywanie popytu na produkty
- Analiza rynku energii: w sektorze energetycznym do prognozowania zużycia, zapotrzebowania i cen energii elektrycznej
- Planowanie zasobów i personelu: w zarządzaniu siłą roboczą, zasobami ludzkimi i planowaniu operacyjnym

Porównywanie modeli

Akaike Information Criterion (AIC)

„Kryterium informacyjne Akaike” jest względną miarą jakości modelu dla danego zbioru danych i pomaga w wyborze spośród skończonego zbioru modeli. Wykorzystuje estymację zmaksymalizowaną wiarygodnością (maximized likelihood estimate) oraz liczbę parametrów do oszacowania informacji utraconych w modelu. Miara AIC stanowi kompromis pomiędzy dokładnością a złożonością modelu. Innymi słowy, zapobiega nadmiernemu dopasowaniu.

Porównywanie modeli

Bayesian Information Criterion (BIC)

Bayesowskie kryterium informacyjne (BIC) to kryterium wyboru modelu spośród skończonego zbioru modeli. Opiera się ono częściowo na funkcji wiarygodności i jest ściśle powiązane z kryterium informacyjnym Akaike (AIC).

Porównywanie modeli

Bayesian Information Criterion (BIC)

Podczas dopasowywania modeli można poprawić jakość poprzez dodanie parametrów, ale może to spowodować nadmierne dopasowanie. BIC rozwiązuje ten problem poprzez wprowadzenie kary za liczbę parametrów w modelu. Kara jest większa w BIC niż w AIC.

BIC jest szeroko stosowany do identyfikacji modeli w szeregach czasowych i regresji liniowej. Można go jednak zastosować do dowolnego zestawu modeli opartych na maksymalnej wiarygodności.

Porównywanie modeli

AIC and BIC

AIC jest powszechnie używany do porównywania modeli. Dla każdego modelu korzystającego z estymacji maksymalnego prawdopodobieństwa automatycznie obliczany jest logarytm wiarygodności, w wyniku czego wyliczenie AIC jest proste.

Porównywanie modeli

AIC and BIC

AIC działa jako karne kryterium logarytmów wiarygodności, zapewniając równowagę pomiędzy dobrym dopasowaniem (wysoka wartość logarytmu wiarygodności) a złożonością (złożone modele są karane bardziej niż proste). AIC jest nieograniczony, więc może przyjmować dowolny typ wartości. Przy porównywaniu modeli należy wybrać ten z najniższym AIC.

Im niższy AIC/BIC, tym lepsza wydajność modelu.

Porównywanie modeli

AIC and BIC

Zarówno BIC, jak i AIC karzą modele, które mają więcej parametrów i nagradzają te, które dobrze pasują do danych. Często wskażą ten sam model.

Jeżeli wynik obu algorytmów się rożni, model wybrany przez BIC jest zwykle prostszy i ma mniejszą liczbę parametrów niż model wybrany przez AIC, ale zwykle nie jest tak dobrze dopasowany do danych, zwłaszcza w przypadku większych zbiorów danych.

Inne modele

Autoregressive Moving Average with Exogenous inputs (ARMAX) służy do analizy szeregu czasowego zależnego od innego szeregu czasowego. Na przykład popyt detaliczny na produkty można modelować w oparciu o poprzedni popyt w połączeniu z szeregami czasowymi związanymi z pogodą, takimi jak temperatura lub opady.

Inne modele

Spectral analysis jest powszechnie używana do przetwarzania sygnałów i podobnych zastosowań inżynieryjnych. Oprogramowanie do rozpoznawania mowy wykorzystuje takie techniki w celu oddzielenia sygnału wypowiadanych słów od ogólnego sygnału, który może zawierać szumy.

Generalized Autoregressive Conditionally Heteroscedastic (GARCH) użyteczny model do rozwiązywania szeregów czasowych o niestałej wariancji lub zmienności. GARCH służy do modelowania aktywności na giełdzie i wahań cen.

Inne modele

Kalman filtering jest przydatny do analizowania danych wejściowych w czasie rzeczywistym w systemie, który może istnieć w określonych stanach. Zwykle istnieje podstawowy model interakcji i wzajemnego oddziaływania komponentów systemu.

Filtr Kalmana przetwarza dane wejściowe, próbuje zidentyfikować błędy na wejściu i przewiduje bieżący stan.

Na przykład filtr Kalmana w systemie nawigacji pojazdu może przetwarzać dane wejściowe, takie jak prędkość i kierunek i aktualizować szacunkową aktualną lokalizację.

Inne modele

Multivariate time series analysis bada wiele szeregów czasowych i ich wzajemny wpływ. Vector ARIMA (VARIMA) rozszerza ARIMA, biorąc pod uwagę wektor kilku szeregów czasowych w określonym czasie, t.

VARIMA może być wykorzystywana w analizach marketingowych, które badają szeregi czasowe związane z ceną i wielkością sprzedaży firmy, a także powiązane szeregi czasowe dla konkurencji.

Przydatne biblioteki

Tsfresh

tsfresh jest potężnym narzędziem do ekstrakcji i selekcji cech szeregów czasowych. Został zaprojektowany tak, aby automatycznie wyodrębniać dużą liczbę cech z danych szeregów czasowych i identyfikować te najbardziej istotne. tsfresh obsługuje szeroką gamę formatów szeregów czasowych i może być używany do różnych zastosowań, takich jak klasyfikacja, grupowanie i regresja.

Przydatne biblioteki

AutoTS

autots to biblioteka Pythona do prognozowania szeregów czasowych. Niektóre funkcje biblioteki to:

- Implementacja algorytmów do jednowymiarowego i wieloczynnikowego prognozowania szeregów czasowych, w tym ARIMA, ETS, Prophet i DeepAR.
- wykonanie automatycznego składania modeli w celu uzyskania najlepszej konfiguracji.
- przewidywania przedziału ufności dla górnej i dolnej granicy.
- Obsługa problematycznych/nieustrukturyzowanych danych poprzez uczenie się optymalnej imputacji NaN i usuwania wartości odstających.

Przydatne biblioteki

Darts

Darts to biblioteka Pythona służąca do przyjaznego dla użytkownika prognozowania i wykrywania anomalii w szeregach czasowych. Zawiera różnorodne modele, od klasycznych, takich jak ARIMA, po głębokie sieci neuronowe. Wszystkich modeli prognozowania można używać w ten sam sposób, używając funkcji fit() i predict(), podobnie jak w przypadku scikit-learn.

Przydatne biblioteki

ETNA

ETNA to łatwe w użyciu narzędzie do prognozowania szeregów czasowych. Zawiera wbudowane zestawy narzędzi do wstępnego przetwarzania szeregów czasowych, generowania funkcji, różnorodnych modeli predykcyjnych z ujednoliconym interfejsem — od klasycznego uczenia maszynowego po sieci neuronowe SOTA, metody łączenia modeli i inteligentne testy historyczne.

Przydatne biblioteki

Greykite

Greykite – Biblioteka zapewnia środowisko ułatwiające opracowanie dobrego modelu prognostycznego, z eksploracyjną analizą danych, wstępnym przetwarzaniem wartości odstających/anomalii, ekstrakcją i inżynierią cech, wyszukiwaniem siatki, oceną, benchmarkingiem i możliwością wizualizacji.

Przydatne biblioteki

Merlion

Merlion – kompleksowa platforma uczenia maszynowego, która obejmuje ładowanie i przekształcanie danych, budowanie i trenowanie modeli, przetwarzanie danych wyjściowych modelu oraz ocenę wydajności modelu.

Przydatne biblioteki

PyCaret

PyCaret to alternatywna, niskopoziomowa biblioteka, której można użyć do skrócenia kodu. PyCaret to zasadniczo opakowanie do Pythona obejmujące kilka bibliotek i frameworków uczenia maszynowego, takich jak scikit-learn, XGBoost, LightGBM, CatBoost, Optuna, Hyperopt, Ray i kilka innych. Zawiera także moduł prognozowania szeregów czasowych.

Przydatne biblioteki

Sktime

Sktime to biblioteka do analizy szeregów czasowych w języku Python. Zapewnia ujednolicony interfejs dla wielu zadań uczenia się szeregów czasowych. Obecnie obejmuje klasyfikację szeregów czasowych, regresję, grupowanie, adnotacje i prognozowanie. Zawiera algorytmy szeregów czasowych i narzędzia kompatybilne ze scikit-learn do tworzenia, dostrajania i sprawdzania poprawności modeli szeregów czasowych.

Przydatne biblioteki

Przykładowy tutorial Pythona dla analizy szeregów czasowych: https://www.kaggle.com/code/prashant111/complete-guide-on-time-series-analysis-in-python

Literatura

Dietrich, D., Heller, B., & Yang, B. Data science & big data analytics: discovering, analysing, visualizing and presenting data. Wiley. (Najnowsze dostępne wydanie)

Deitel, P., & Deitel, H. Python for programmers: with Big Data and artificial intelligence case studies. (Najnowsze dostępne wydanie)

Materiały dodatkowe

https://www.linkedin.com/advice/1/what-some-sampling-challenges-solutions-big-data
https://www.linkedin.com/advice/3/how-can-you-handle-missing-data-without-affecting-r4t2f?trk=cq
https://web.ece.ucsb.edu/~parhami/pubs_folder/parh19b-ebdt-parallel-proc-big-data.pdf
https://www.spiceworks.com/tech/iot/articles/what-is-parallel-processing/
https://www.machinelearningplus.com/python/parallel-processing-python/

Materiały dodatkowe

https://www.freecodecamp.org/news/8-clustering-algorithms-in-machine-learning-that-all-data-scientists-should-know/

https://www.educative.io/answers/what-is-association-rule-mining

https://hasonss.com/blogs/association-rule-in-data-mining/

Materiały dodatkowe

https://medium.com/@codekalimi/use-cases-of-linear-regression-models-b7ae3f2a3713

https://www.v7labs.com/blog/logistic-regression

https://mailchimp.com/resources/machine-learning-regression/

Materiały dodatkowe

L. Breiman, “Random Forests,” Machine Learning, vol. 45, no. 1, pp. 5–32, 2001.
J. R. Quinlan, “Bagging, Boosting, and C4. 5,” AAAI/IAAI, vol. 1, 1996.
D. Michie, D. J. Spiegelhalter, and C. C. Taylor, Machine Learning, Neural and Statistical Classification, New York: Ellis Horwood, 1994.
I. H. Witten, E. Frank, and M. A. Hall, “The Bootstrap,” in Data Mining, Burlington, Massachusetts, Morgan Kaufmann, 2011, pp. 155–156.
L. Breiman, “Bagging Predictors,” Machine Learning, vol. 24, no. 2, pp. 123–140, 1996.
N. Cristianini and J. Shawe-Taylor, An Introduction to Support Vector Machines
and Other Kernel-Based Learning Methods, Cambridge, United Kingdom: Cambridge university press, 2000.

Materiały dodatkowe

https://medium.com/@vaibhav1403/the-arma-autoregressive-moving-average-model-is-a-popular-statistical-model-used-in-time-series-24ce43049366
https://medium.com/@ritusantra/introduction-to-arima-model-c8925103f4c7
https://www.youtube.com/watch?v=dXND1OEBABI
https://medium.com/@ritusantra/auto-correlation-function-acf-and-partial-auto-correlation-function-pacf-e29ec2db2b1b

Materiały dodatkowe

https://medium.com/@analyttica/akaike-information-criterion-aic-7a4b58bce206
https://medium.com/@analyttica/what-is-bayesian-information-criterion-bic-b3396a894be6
https://kinder-chen.medium.com/aic-and-bic-41c8db2973e8
https://towardsdatascience.com/top-5-time-series-analytics-71a46fbda379
https://medium.com/@opentimeseries/10-best-all-in-one-time-series-python-packages-fd24842d8d6c

PYTANIA?

dr inż. Izabella Antoniuk
Instytut Informatyki Technicznej, Katedra Sztucznej Inteligencji, Zakład Analizy Obrazów
izabella_antoniuk@sggw.edu.pl